

**Министерство науки и высшего образования Российской Федерации**  
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ  
**НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО**

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА**

**Прогнозирование фондового рынка РФ с использованием методов глубокого обучения**

**Обучающийся:** Смирнов Алексей Евгеньевич

**Квалификация:** Магистратура

**Факультет/институт/кластер:** Высшая школа цифровой культуры

**Направление подготовки:** 02.04.03 Математическое обеспечение и администрирование информационных систем

**Образовательная программа:** Аналитика данных

**Группа:** S4202

**Руководитель ВКР:** Азимов Рустам Шухратуллович

Обучающийся

Смирнов Алексей Евгеньевич

Дата: 25.05.2026

## **ЗАДАНИЕ**

### **Основные вопросы, подлежащие разработке:**

#### Цель работы

Разработка и эмпирическое тестирование адаптивной торговой стратегии на основе моделей глубокого обучения для высоколиквидных активов российского фондового рынка, обеспечивающей статистически значимое превышение доходности над пассивными и макроэкономическими бенчмарками при контролируемом уровне риска.

#### Основные задачи, подлежащие разработке

1. Провести обзор литературы: гипотеза эффективного рынка (ЕМН) и альтернативные теории, эволюция методов прогнозирования временных рядов от классических моделей до современных архитектур глубокого обучения.
2. Проанализировать специфические особенности и динамику российского фондового рынка.
3. Собрать, очистить и подготовить исходные данные: исторические котировки высоколиквидных инструментов биржи.
4. Разработать и реализовать архитектуру нейронной сети и торговый алгоритм с элементами риск-менеджмента.
5. Провести тестирование на исторических данных, оценить эффективность по ключевым метрикам, выполнить сравнительный анализ с эталонными инвестиционными стратегиями.
6. Сформулировать выводы о практической применимости полученной стратегии в условиях российского рынка и перспективах её дальнейшего развития.

#### Исходные данные к работе

1. Котировки по ликвидным инструментам биржи. Источники: официальное API Московской Биржи, Tinkoff OpenAPI, данные Финам.
2. Макроэкономические показатели ЦБ РФ: кривая бескупонной доходности, инфляция, ключевые ставки, средневзвешенные ставки по вкладам.

#### Содержание работы

1. Введение.
2. Обзор литературы.
3. Анализ российского фондового рынка.
4. Сбор и подготовка данных.
5. Реализация моделей глубокого обучения и торгового алгоритма.
6. Результаты и сравнительный анализ.
7. Заключение и рекомендации.

### **Форма представления материалов ВКР:**

Текст ВКР, презентация

**Дополнительно:**

Программный код

**Дата выдачи задания**

06.04.2026

Согласовано:

Руководитель ВКР Азимов Рустам Шухратуллович, ВШ ЦК, доцент (квалификационная категория "ординарный доцент"), осн.

## **АННОТАЦИЯ**

### **Цель исследования**

Разработка адаптивной торговой стратегии на основе моделей глубокого обучения для высоколиквидных активов российского фондового рынка: эмпирическая оценка экономической эффективности и доказательство статистически значимого превышения доходности над эталонными стратегиями при соблюдении целевых показателей риска.

### **Задачи, решаемые в ВКР**

1. Исследовать специфику и динамические характеристики высоколиквидных активов российского фондового рынка для определения параметров моделирования.
2. Сформировать и предобработать эмпирическую базу исследования, включая исторические котировки и макроэкономические индикаторы.
3. Разработать и программно реализовать архитектуры моделей глубокого обучения, адаптированные под особенности прогнозирования финансовых временных рядов.
4. Сконструировать торговый алгоритм на основе предсказаний моделей с интегрированным механизмом динамического риск-менеджмента.
5. Провести эмпирическое тестирование разработанной стратегии на исторических данных по схеме скользящего окна (Walk-Forward Validation) и оценить ее риск-скорректированную экономическую эффективность.
6. Осуществить сравнительный анализ полученных результатов с эталонными (пассивными и макроэкономическими) стратегиями.
7. Оценить практическую применимость адаптивной стратегии в условиях российского рынка и определить перспективы дальнейших исследований.

### **Краткая характеристика полученных результатов**

1. Доказано, что применение фиксированного порога разметки целевой переменной неэффективно для российского рынка. Установлено, что оптимальный параметр чувствительности (альфа) определяется профилем актива: для высоковолатильных инструментов требуется его снижение, а для трендовых — повышение, что объективно обосновывает необходимость методологии адаптивной волатильной разметки (Dynamic Volatility Labeling).
2. Эмпирически подтверждено, что классические модели машинного обучения (Ridge, LightGBM, CatBoost) не демонстрируют способности генерировать статистически значимую доходность на внутридневных данных российского рынка после вычета транзакционных издержек. В отличие от них, разработанные архитектуры глубокого обучения (1D-CNN) формируют устойчивые предсказательные паттерны, конвертируемые

в экономически значимую доходность.

3. В условиях высокой макроэкономической волатильности и экстремальных просадок пассивных стратегий разработанная адаптивная стратегия успешно выполняет функцию контроля риска. За счет своевременной идентификации негативных рыночных режимов, выхода в кэш и применения алгоритма динамического безубытка, стратегия обеспечивает существенное снижение максимальной просадки по сравнению с эталонным бенчмарком.

4. Посредством строгих статистических тестов (расчет минимально детектируемого эффекта, MDE) доказано, что разработанная стратегия генерирует положительную альфу — чистое превышение риск-скорректированной доходности над пассивными и макроэкономическими эталонами, при этом результат не является следствием случайного совпадения или переобучения.

Согласовано:

Руководитель ВКР Азимов Рустам Шухратуллович, ВШ ЦК, доцент (квалификационная категория "ординарный доцент"), осн.

16.05.2026

# СОДЕРЖАНИЕ

|                                                                                                     |    |
|-----------------------------------------------------------------------------------------------------|----|
| ВВЕДЕНИЕ .....                                                                                      | 4  |
| 1 Обзор литературы.....                                                                             | 8  |
| 1.1 Современные методы и количественный анализ в финансах .....                                     | 8  |
| 1.2 Особенности и динамика российского фондового рынка .....                                        | 9  |
| 1.3 Архитектуры глубокого обучения для временных рядов в финансах<br>.....                          | 12 |
| 1.4 Интеграция альтернативных данных и использование методов<br>обработки естественных языков ..... | 14 |
| 1.5 Критерий Келли и его применение в алгоритмической торговле                                      | 16 |
| 1.6 Вейвлет-денойзинг как метод предобработки финансовых<br>временных рядов .....                   | 17 |
| 1.7 Обучение с подкреплением и торговые стратегии .....                                             | 18 |
| 1.8 Вызовы, перспективы и обоснование выбора подхода в работе ..                                    | 19 |
| 2 Анализ и реализация .....                                                                         | 22 |
| 2.1 Сбор и подготовка данных .....                                                                  | 25 |
| 2.2 Проектирование пространства признаков .....                                                     | 26 |
| 2.3 Методология адаптивной разметки целевой переменной .....                                        | 31 |
| 2.4 Эмпирическое обоснование подбора параметра чувствительности<br>$\alpha$ .....                   | 33 |
| 2.5 Обработка данных с помощью вейвлет-денойзинга .....                                             | 36 |
| 2.6 Базовые модели машинного обучения и эталонные<br>инвестиционные модели .....                    | 39 |
| 2.7 Архитектуры моделей глубокого обучения .....                                                    | 41 |
| 2.8 Тестирование стратегии на исторических данных и риск-<br>менеджмент .....                       | 48 |
| 3 Результаты и сравнительный анализ .....                                                           | 52 |
| 3.1 Анализ эффективности классических моделей машинного<br>обучения .....                           | 52 |

|                                                                          |    |
|--------------------------------------------------------------------------|----|
| 3.2 Сравнительный анализ архитектур глубокого обучения .....             | 57 |
| 3.3 Анализ влияния пространства признаков .....                          | 59 |
| 3.4 Риск-менеджмент: динамический безубыток.....                         | 61 |
| 3.5 Минимально детектируемый эффект и статистическая значимость<br>..... | 63 |
| ЗАКЛЮЧЕНИЕ.....                                                          | 65 |
| СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ .....                                   | 67 |
| ПРИЛОЖЕНИЕ А .....                                                       | 73 |

# ВВЕДЕНИЕ

Ценовая динамика активов на финансовых рынках формируется под влиянием макроэкономических факторов, участников торгов, ликвидности, новостного фона и поведения инвесторов. На российском фондовом рынке после 2022 года усилилось влияние частных инвесторов, возросла чувствительность рынка к политике.

**Актуальность** темы связана с разработкой методов прогнозирования и риск-менеджмента, способных учитывать нестационарность внутридневных финансовых данных. Модели глубокого обучения позволяют извлекать нелинейные зависимости из временных рядов. Однако их применение в алгоритмической торговле требует проверки по экономическим показателям: доходности, устойчивости к транзакционным издержкам и статистической значимости результата.

**Степень разработанности** темы характеризуется наличием исследований, посвященных применению машинного и глубокого обучения в задачах прогнозирования финансовых рядов. В литературе рассматриваются рекуррентные, сверточные, гибридные и трансформерные архитектуры. Также остаются нерешенные вопросы: выбор корректной разметки целевой переменной на нестационарных данных, оценка устойчивости моделей на российском рынке.

**Решаемая проблема** заключается в том, что модели прогнозирования не всегда дают практически применимые торговые стратегии. Минимизация ошибки прогноза не гарантирует положительный финансовый результат, особенно на высокочастотных данных, где значимы рыночный шум, комиссии, проскальзывание и смена рыночных режимов. Поэтому в работе рассматривается не только задача построения прогностической модели, но и задача проверки ее применимости в составе торгового контура с динамическим риск-менеджментом.



**Целью исследования** является разработка и эмпирическая проверка адаптивной торговой стратегии на основе моделей глубокого обучения для высоколиквидных активов российского фондового рынка, а также оценка ее статистической и экономической значимости с учетом транзакционных издержек и альтернативных способов размещения капитала.

Для достижения поставленной цели необходимо решить следующие **задачи**:

1. Исследовать особенности высоколиквидных активов российского фондового рынка и определить факторы, влияющие на построение прогностической модели.
2. Сформировать эмпирическую базу исследования на основе исторических внутридневных котировок и дополнительных рыночных и макроэкономических признаков.
3. Разработать процедуру адаптивной разметки целевой переменной с учетом локальной волатильности актива.
4. Реализовать и сравнить классические модели машинного обучения и архитектуры глубокого обучения для классификации рыночных состояний.
5. Проверить влияние технических индикаторов, макроэкономических признаков и вейвлет-денойзинга на качество торговых результатов.
6. Сконструировать торговый алгоритм на основе вероятностных выходов моделей и механизма динамического риск-менеджмента.
7. Провести тестирование стратегий на исторических данных по схеме walk-forward validation с учетом комиссий и проскальзывания.
8. Оценить статистическую значимость результатов и сопоставить их с пассивными и безрисковыми альтернативами.

**Объектом исследования** являются внутридневные котировки высоколиквидных финансовых инструментов российского фондового рынка.

**Предметом исследования** являются методы прогнозирования направленных ценовых движений с использованием моделей машинного

обучения, глубокого обучения, адаптивной разметки данных и правил риск-менеджмента.

**Методологическую основу** исследования составляют методы анализа временных рядов, машинного обучения, глубокого обучения, цифровой обработки сигналов и статистической проверки гипотез. В работе используются архитектуры 1D-CNN, BiLSTM с механизмом внимания и MLP, метод вейвлет-денойзинга, процедура адаптивной волатильной разметки и расчет минимально детектируемого эффекта. Программная реализация выполнена на языке Python с использованием библиотек для обработки данных, машинного обучения и нейросетевого моделирования.

**Научная новизна** работы состоит в следующем:

1. Предложена и эмпирически проверена процедура адаптивной волатильной разметки целевой переменной для внутридневных данных российского фондового рынка.

2. Проведено сравнение классических моделей машинного обучения и архитектур глубокого обучения в единой схеме исторического тестирования с учетом транзакционных издержек.

3. Показано, что влияние признаковов групп зависит от архитектуры модели и типа актива: технические индикаторы могут ухудшать результаты рекуррентных и полносвязных моделей, при этом вейвлет-денойзинг способен улучшать результаты сверточных архитектур на отдельных инструментах.

4. Установлено, что на части активов модели глубокого обучения формируют статистически значимый предиктивный сигнал, вместе с тем экономическое сравнение с безрисковой ставкой и пассивными альтернативами не является устойчивым для всех инструментов.

**Практическая значимость** работы заключается в возможности использования разработанного подхода как компонента системы риск-менеджмента и фильтрации рыночных режимов. Полученные результаты могут быть применены при разработке торговых алгоритмов, где модель

используется как инструмент отбора сигналов, контроля просадки и оценки рыночного состояния.

# **1 Обзор литературы**

В разделе приведен анализ изменения методов машинного обучения от классических алгоритмов до современных архитектур глубокого обучения. Внимание уделено трансформации рынков под влиянием алгоритмизации. Обзор опирается на работы по теории эффективного рынка, современные обзоры методов глубокого обучения в финансах и актуальные кейсы по российскому фондовому рынку.

## **1.1 Современные методы и количественный анализ в финансах**

Современная методология прогнозирования финансовых рынков основана на использовании глубокого обучения и классического количественного анализа. Классическая гипотеза эффективного рынка (ЕМН) Ю. Фамы [1] и доказательство случайности цен П. Самуэльсона [2] долгое время доминировали, однако эмпирические аномалии [4, 5] и гипотеза адаптивных рынков Э. Ло [3] показали наличие предсказуемых паттернов, особенно в периоды стресса и высокой волатильности.

Традиционные статистические модели (ARIMA, GARCH) и технический анализ [6–8] демонстрируют ограниченную способность улавливать нелинейные зависимости в зашумленных данных [9, 10]. Переход к машинному обучению начался с SVM и ANN, при этом наибольшие успехи достигнуты при появлении глубоких нейронных сетей [10]. Обзор Ozbayoglu et al. проанализировал 144 работы по DL (Deep Learning) в финансах и показал доминирование рекуррентных нейронных сетей (RNN, включая LSTM) – более 40 % публикаций, за ними следуют DNN и CNN [30]. Авторы подчёркивают, что DL-модели используются в задачах алгоритмической торговли, управлении портфелем и анализе настроений. Zhang et al. в обзоре

2020–2022 гг. выделили ключевые архитектуры для предсказания финансовых временных рядов [31]:

- RNN и вариации (LSTM, GRU, BiLSTM, ConvLSTM) – лучше всего подходят для получения долгосрочных зависимостей.
- CRNN (CNN + RNN) – превосходят одиночные модели за счёт совместного извлечения пространственно-временных признаков.
- Transformers и Temporal Fusion Transformers (TFT) – эффективны для длинных последовательностей.
- GNN, GAN, Autoencoders, DQNN – перспективные направления, которые будут развиваться на горизонте нескольких лет.

Wang et al. предложили Cross-Data-Type 1D-CNN, которая автоматически извлекает признаки из сырых OHLCV-данных без технических индикаторов и превосходит SVM и MLP по коэффициенту Шарпа на 99–245 % на фьючерсном рынке [32]. В 2024–2025 гг. акцент сместился на мультимодальные и гибридные модели. Интеграция LLM для новостных лент и Telegram-каналов может снижать ошибку прогноза в периоды повышенной волатильности.

## **1.2 Особенности и динамика российского фондового рынка**

Российский фондовый рынок имеет ряд особенностей, которые повышают интерес к применению DL-моделей. После 2022 г. доля частных инвесторов превысила 80 %, что привело к росту высокочастотной торговли и поведенческих факторов [19]. Высокая чувствительность к монетарной политике ЦБ РФ, кривой бескупонной доходности и инфляционным ожиданиям делает целесообразной проверку макроэкономических признаков [20, 21]. Рынок РФ переживает структурные сдвиги из-за геополитики и санкций. Поэтому модели с адаптивным переобучением могут быть устойчивее при смене рыночного режима [22, 23]. Исследования 2025 года

демонстрируют применимость методов глубокого обучения именно на данных российского фондового рынка:

- В исследовании Сулимова и Лиэлла [34] предложена мультимодальная модель прогнозирования российского фондового рынка, объединяющая числовые временные ряды и текстовую информацию из новостных агентств. Применение методов анализа тональности текстов позволило улучшить качество предсказаний и продемонстрировать улучшение результатов по сравнению с базовыми моделями, опирающимися только на ценовую историю.

- Хазиев Г.А. и Соколова Т.В. построили индекс настроений инвесторов RSMI на основе анализа сообщений в Telegram-каналах и приложении Tinkoff Pulse. Модель LSTM, дополненная данным индексом, продемонстрировала статистически значимое превосходство над методами градиентного бустинга и случайного леса при прогнозировании доходности 78 эмитентов за период 2018–2022 гг. [35].

- Теплова Т. и др. предложили гибридную архитектуру TCN-LSTM-Attention для системы раннего предупреждения кризисов на российском фондовом рынке. Модель эффективно работает с несбалансированными данными и достигает точности 78,7 % при прогнозировании кризисных событий [36].

- В исследовании Chatzis и соавторов применены методы глубокого и статистического машинного обучения для прогнозирования кризисных явлений на фондовых рынках, продемонстрировавшие высокую статистическую значимость предсказаний [37].

Чувствительность к монетарной политике ЦБ РФ проявляется в быстром реагировании на изменения ключевой ставки. Исследования показывают, что снижение процентных ставок стимулирует переток капитала из депозитов в акции, что приводит к росту рыночной капитализации и увеличению прибылей компаний [38]. Для корректной интеграции макроэкономических

показателей в модели глубокого обучения важно использовать проверенные источники данных. Методология расчёта индекса потребительских цен (ИПЦ) обеспечивает воспроизводимость расчётов инфляции [27]. Бюллетени Банка России содержат информацию о ключевой ставке, параметрах кривой бескупонной доходности и средневзвешенных ставках по депозитам [28]. Работы, посвященные развивающимся рынкам в постпандемийный период, фиксируют более высокую устойчивость компаний, ориентированных на внутренний спрос, по сравнению с экспортными отраслями [39]. Специфика российского рынка во многом определяется поведенческими факторами: в периоды макроэкономической турбулентности инвесторы демонстрируют избыточную реакцию на информационные шоки. Эта рыночная неэффективность создает дополнительную базу для построения алгоритмических стратегий [40]. Оценка профиля риск-доходности выделяет активы финансового и нефтегазового секторов, которые обладают благоприятными мультипликаторами и прогнозируемым совокупным доходом [41]. Тем не менее, фундаментальные показатели тесно связаны с геополитической конъюнктурой. Санкционное давление и непредсказуемость дивидендных выплат экспортных компаний выступают основными источниками волатильности, что требует обязательного учета при проектировании прогнозных моделей [42].

В ожидании снижения ставок и роста прибыли ценовые модели могут показывать недооцененные результаты. Мультимодальные подходы лучше учитывают настроения инвесторов и макроэкономический контекст. Риски санкций требуют обучения в реальном времени для адаптации [39, 42]. Специфика фондового рынка РФ усиливает роль гибридных подходов: интеграция макро-индикаторов и анализа настроений позволяет повысить точность прогнозов на 20–30 % [34, 35].

### 1.3 Архитектуры глубокого обучения для временных рядов в финансах

Классические рекуррентные нейронные сети долгое время выступали стандартом при работе с последовательными данными благодаря способности поддерживать скрытое состояние  $h_t$ , собирающее информацию о предыдущих наблюдениях. На практике, базовые RNN демонстрируют ограниченную применимость: при обработке последовательностей длиной более 50–100 шагов градиенты в процессе обратного распространения либо экспоненциально затухают, либо неограниченно возрастают, что делает невозможным обучение долгосрочным зависимостям [11, 29]. Для финансовых временных рядов эта проблема усугубляется: низкочастотная составляющая (макроэкономический тренд, смена режима рынка) часто отделена от высокочастотного сигнала десятками и сотнями наблюдений.

Проблему затухания градиента в рекуррентных сетях решает архитектура LSTM, предложенная Hochreiter и Schmidhuber [11]. Вместо скалярного скрытого состояния в ней используется векторная ячейка памяти, состояние которой регулируется системой вентиля: забывания, входным и выходным. Такой механизм позволяет информации проходить через цепочку состояний практически без нелинейных искажений, что и обеспечивает стабильный поток градиентов при обучении на длинных последовательностях. В задачах прогнозирования финансовых рядов LSTM показывает стабильные результаты на дневных и недельных таймфреймах (горизонты от 1 до 30 дней) [30, 31]. На таких интервалах соотношение сигнал/шум ещё остаётся приемлемым для обучения, а сами ценовые зависимости обладают выраженной инерционностью, которую рекуррентная архитектура успешно улавливает.

Архитектура **Gated Recurrent Unit (GRU)**, предложенная Cho et al. GRU объединяет входной вентиль и вентиль забывания в единый механизм



обновления, а также сливает состояния ячейки и скрытого слоя в одну переменную. Это уменьшает число обучаемых параметров примерно на 25–30 % при сохранении сопоставимого с LSTM качества аппроксимации. На коротких и зашумленных выборках, характерных для внутридневной торговли, GRU оказывается предпочтительнее: меньшая ёмкость модели снижает риск переобучения на стохастических флуктуациях, а ускоренное обучение облегчает подбор гиперпараметров и проведение walk-forward валидации. Применение рекуррентных архитектур к высокочастотным данным российского фондового рынка сопряжено с рядом фундаментальных ограничений, которые проявляются на этапе эмпирической проверки:

1. **Накопление микроструктурного шума.** На 5-минутных таймфреймах скрытое состояние  $h_t$  вынуждено обрабатывать значительный объём шума, обусловленного дискретностью стакана заявок, случайными крупными сделками и поведенческими реакциями розничных участников [19, 40]. Так как рекуррентный блок не имеет встроенного механизма фильтрации, шум последовательно накапливается в ячейке памяти и подавляет слабые предиктивные сигналы.

2. **Проблема двунаправленных архитектур.** Модификация BiLSTM, обеспечивающая более полное использование контекста, в задачах онлайн-торговли требует особой осторожности: обратный проход по последовательности создаёт риск скрытого заглядывания в будущее (look-ahead bias), если процедура формирования обучающих окон реализована с нарушениями хронологической изоляции [25]. В данной работе двунаправленная архитектура используется исключительно в режиме классификации уже сформированных исторических окон, где утечка информации исключена конструкцией валидатора.

3. **Вычислительная неэффективность.** Последовательная природа рекуррентного прохода препятствует распараллеливанию вычислений на GPU, что при объёмах обучающей выборки в сотни тысяч 5-минутных баров

приводит к неприемлемо длительным циклам обучения и усложняет инкрементальное дообучение модели в рамках схемы скользящего окна.

4. **Чувствительность к концептуальному дрейфу.** При резких структурных сдвигах сеть склонна к забыванию ранее выученных паттернов. Это требует применения специализированных механизмов регуляризации или периодического переобучения с нуля [22, 23]. Эти ограничения определили направление исследования.

**Сверточные нейронные сети (CNN).** Ключевая особенность одномерных сверток это поиск локальных инвариантов. В контексте финансовых рядов свёрточные фильтры работают как автоматические детекторы микроструктур: они учатся находить аналоги классических свечных формаций («молот», «поглощение») и зоны локальных уровней без ручной разметки. Актуальные бенчмарки 2025–2026 годов отмечают, что на коротких таймфреймах (1–5 дней) 1D-CNN часто обходят по качеству рекуррентные сети. Причины прагматичные: свертки вычислительно легче, а благодаря архитектуре локальных окон они структурно менее чувствительны к рыночному шуму, из-за чего реже уходят в переобучение на коротких выборках.

## **1.4 Интеграция альтернативных данных и использование методов обработки естественных языков**

Финансовые рынки сильно зависят от информационного фона: новости, отчёты, социальные сети и Telegram-каналы быстро влияют на мнения участников рынка. Традиционные ценовые ряды захватывают только историческую динамику, поэтому мультимодальные подходы становятся современным стандартом [30, 34].

LSTM на мультимодальных входах снизила MAPE на 55 % по сравнению с ценовой моделью. Аналогично, Хазиев [35] построил RSMI-индекс настроений по Telegram и Tinkoff Pulse, вследствие чего LSTM в паре

с RSMI превзошла градиентный бустинг на 78 эмитентах московской биржи (2018–2022). Дополнительные возможности открывает использование альтернативных данных за пределами новостных лент. Dierckx et al. исследовали предсказание движений рыночной ожидаемой волатильности (implied volatility) с помощью статистики Google News и трафика страниц Wikipedia [44]. Авторы применили классические модели машинного обучения: логистическую регрессию, метод опорных векторов с радиально-базисной функцией ядра (RBF-SVM) и AdaBoost. Задача сформулирована как бинарная классификация движения ожидаемой волатильности на следующий день:

$$y_i = \begin{cases} 1, & \text{если } \Delta IV_{t+1} > 0 \\ 0, & \text{иначе} \end{cases},$$

где  $\Delta IV_{t+1}$  – изменение ожидаемой волатильности актива между текущим и следующим торговым днём.

Обзор возможностей языкового моделирования в финансах представлен в работе Татаринов и др. В ней проанализировано более 374 публикаций за период 2017–2024 гг. [45]. Внимание уделено проблемам: недостаточной проработке многоязычных данных и слабой представленности кризисных сценариев. Реализацию мультимодального прогнозирования демонстрирует работа Taylor et al., где для предсказания трендов акций применяется облегчённая версия BERT в сочетании с ценовыми данными [46]. В работе используется механизм позднего слияния: эмбединги текста  $e_{text} \in \mathbb{R}^d$ , получаемые после прохождения через многослойный трансформер-энкодер модели, объединяются с вектором признаков временного ряда  $e_{price}$ :

$$z_{fused} = \text{Concat}(e_{text}, e_{price}).$$

Классификация тренда осуществляется полносвязным слоем с функцией активации softmax и кросс-энтропийной функцией потерь:

$$\mathcal{L} = - \sum_{c=1}^C y_c \log(\hat{y}_c),$$

где  $C = 3$  – классы (hold, buy, sell). Подход позволяет динамически взвешивать вклад технических и текстовых факторов.

## 1.5 Критерий Келли и его применение в алгоритмической торговле

**Критерий Келли** – это метод оптимизации размера позиции в условиях неопределённости, направленный на максимизацию роста капитала [48]. Подход предложен Дж. Л. Келли-младшим в 1956 году в работе «A New Interpretation of Information Rate». Автор показывает связь между теорией информации и оптимальным управлением капиталом в повторяющихся стохастических процессах [48]. Современный подход предложил Thorp, адаптировав теоретические положения для задач портфельной оптимизации и оценки риска [47]. Для бинарного исхода формула Критерия Келли имеет вид:

$$f^* = \frac{bp-q}{b} = \frac{p(b+1)-1}{b},$$

где  $f^*$  - оптимальная доля капитала, подлежащая инвестированию в текущую сделку,  $b$  – чистый коэффициент выигрыша (отношение прибыли к риску,  $b>0$ ),  $p$  – вероятность благоприятного исхода,  $q = 1 - p$  – вероятность неблагоприятного исхода. Формула выводится из условия максимизации математического ожидания логарифма капитала [48]. Cover и Thomas отмечают, что подход эквивалентен максимизации энтропийной скорости роста и обладает свойством эргодичности в стационарных условиях [49].

В контексте финансов применение Критерия Келли требует адаптации, поскольку параметры  $p$  и  $b$  не являются известными априори и должны оцениваться на основе исторических данных или прогнозных моделей [50]. Основные этапы практической реализации включают оценку вероятности успеха ( $p$ ) через историческую частоту прибыльных сделок торговой стратегии или вероятностные выходы моделей машинного обучения. Оценка выигрыша ( $b$ ) рассчитывается как отношение средней прибыли прибыльных сделок к среднему убытку убыточных сделок (Profit Factor) [48].

Модификатором является **Фракционный Критерий Келли**:

$$f_{frac} = c \cdot f^*,$$

где  $c \in [0.3; 0.5]$ . Классический критерий Келли теоретически максимизирует темп роста капитала, но в реальной торговле оказывается избыточно агрессивным. Haghani и Dewey [50] эмпирически показали, что этот метод чувствителен к ошибкам оценки параметров: даже небольшое завышение вероятности успеха сделки ведет к увеличению рекомендуемой позиции и, как следствие, к повышенному риску потери капитала. Поэтому на практике применяется дробный Келли [51]. Метод сознательно жертвует частью потенциальной доходности ради устойчивости [48].

## **1.6 Вейвлет-денойзинг как метод предобработки финансовых временных рядов**

Вейвлет-денойзинг – это эффективный метод очистки сигналов и изображений от шума с помощью вейвлет-преобразования [52]. Дискретное вейвлет-преобразование (DWT) реализуется через каскад фильтров низких и высоких частот. Наиболее распространённые подходы к удалению шума включают универсальный порог по методу Донохо–Джонстона:

$$\lambda = \sigma \sqrt{2 \ln N},$$

где  $\sigma$  – оценка уровня шума через медиану абсолютных отклонений детализирующих коэффициентов,  $N$  – длина ряда [54].

Методы SureShrink и BayesShrink подбирают порог для каждого уровня декомпозиции на основе критерия Стеина или байесовских оценок [52]. Исследования показывают, что вейвлет-денойзинг данных может повысить точность прогнозных моделей на 5–15% за счёт снижения влияния микроструктурного шума и выбросов [52, 54]. Рекомендуется проводить кросс-валидацию выбора вейвлета и уровня декомпозиции на исторических данных [55].

## 1.7 Обучение с подкреплением и торговые стратегии

Глубокое обучение с подкреплением (DRL) обеспечивает прямую оптимизацию торговых стратегий путём формирования управляющих воздействий (buy, sell, hold, размер позиции). Целевой функцией выступает максимизация суммарной доходности при минимизации риск-метрик, таких как коэффициент Шарпа и максимальная просадка. Наиболее эффективными признаны алгоритмы семейства actor-critic: PPO (Proximal Policy Optimization), демонстрирующий высокую стабильность за счёт использования искусственной функции оптимизации с ограничением, а также DDPG и TD3, адаптированные для работы в непрерывном пространстве признаков. Актуальным направлением исследований в период 2025–2026 гг. является применение ансамблевых методов (например, гибридизация PPO, A2C и DDPG). Это позволяет усреднять агентов и повышать устойчивость торговой системы в условиях рыночной неопределенности.

Системный обзор современного состояния DRL в финансовых решениях представлен в работе Hoque et al. [56]. Авторы проанализировали 167 статей 2017–2025 гг. и показали сопоставление гибридных архитектур (LSTM-DQN, CNN-PPO) в задачах обеспечения ликвидности, портфельной оптимизации и алгоритмической торговли. Анализ интеграции RL и NLP для торговли проведён Ferrell и Thomson McInnes [57]. В обзоре 22 работ 2018–2024 гг. они выделяют основные вызовы: отсутствие унифицированных наборов данных, проблемы воспроизводимости результатов и перспективы интеграции больших языковых моделей (LLM) для обогащения пространства признаков текстовыми данными из новостей и социальных сетей. Теоретические основы применения глубокого обучения с подкреплением в финансах изложены в обзоре Hambly et al. [58]. Авторы описывают задачу алгоритмической торговли в рамках марковского процесса принятия решений (MDP), где состояние  $s_t$  включает ценовые характеристики, технические индикаторы и

стохастические факторы рынка, действие  $a_t$  соответствует торговому решению (покупка, продажа, удержание позиции), а функция вознаграждения  $r_t$  конструируется как риск-скорректированная доходность портфеля. Особое внимание уделяется математической строгости формулировок и сходимости алгоритмов в условиях нестационарности финансовых временных рядов. Подчёркивается необходимость учёта транзакционных издержек, рыночного воздействия и корректного тестирования на данных вне периода обучения при переходе от теоретических моделей к практической реализации торговых систем. Перспективы использования глубокого обучения с подкреплением для оптимизации торговых стратегий активно исследуются в зарубежной литературе. Тэте и Эрнст [59] определили процесс алгоритмической торговли как марковский процесс принятия решений. Их исследование показало, что обученный DRL-агент способен адаптироваться к рыночным условиям и демонстрировать эффективность, значительно превышающую результаты традиционных базовых стратегий. Пономарев Е. С., Оселедец И. В., Чихоцкий А. С. показали применение RL для конструирования полностью автономных систем покупки/продажи на финансовых рынках, где модель самостоятельно обучается оптимальной политике без предварительной разметки данных [60].

## **1.8 Вызовы, перспективы и обоснование выбора подхода в работе**

При разработке прогностических моделей для финансовых рынков ключевым вызовом остается нестационарность временных рядов, приводящая к переобучению алгоритмов на исторических данных. Как показывают систематические обзоры, в условиях резких смен рыночных состояний традиционные модели теряют до 40–60 % предсказательной способности уже через 3–6 месяцев после обучения [56]. Для минимизации рисков в работе применяются методы регуляризации и контроль хронологической последовательности при формировании обучающей и тестовой выборок. С

учетом растущих требований регуляторов к прозрачности алгоритмической торговли, важным аспектом становится переход от концепции «черного ящика» к интерпретируемому ИИ (XAI). Использование методов SHAP и LIME позволяет количественно оценить вклад различных групп признаков – от классических котировок (OHLCV) до макроэкономических показателей. Это необходимо для безопасности и повышения доверия институциональных инвесторов.

Применение DRL на высоковолатильном российском рынке связано с ограничениями. В условиях частых структурных сдвигов и нестационарности DRL-агенты (PPO, DDPG) демонстрируют нестабильность сходимости и подвержены существенному забыванию, так как формирование устойчивой политики требует объемов стационарных данных, недостижимых в реальной рыночной среде. Тестирование RL-агентов на исторических данных сопряжено с высоким риском скрытой утечки данных из будущего при проектировании среды и функции вознаграждения [61]. Поэтому в работе сделан выбор в пользу обучения с учителем (Supervised Learning) в задаче классификации рыночных состояний. Архитектура 1D-CNN с адаптивной волатильной разметкой выбрана как наиболее устойчивая к микроструктурному шуму, характерному для российского рынка. Переход от прямой регрессии цены к классификации (Buy/Sell/Hold) с использованием динамического порога уверенности позволяет модели фильтровать неопределенные рыночные состояния. Дополнительно внедренный механизм динамического безубытка (перенос стоп-лосса в точку входа) ограничивает левый хвост распределения убытков, обеспечивая контроль рисков на уровне, недостижимом для классических регрессионных моделей.

В качестве перспективных направлений развития исследования, способных преодолеть выявленные ограничения в будущем, рассматриваются:

- **Многоагентные системы (MARL).** Позволяют моделировать взаимодействие участников с различными временными горизонтами



инвестирования. Это повышает устойчивость стратегий в условиях частичной наблюдаемости рынка [63].

- **Непрерывное обучение** для адаптации алгоритмов к резким изменениям макроэкономических режимов без забывания. Перспективным подходом является Elastic Weight Consolidation (EWC), где член регуляризации штрафует сильное изменение весов, значимых для предыдущих рыночных режимов [56].

- **Квантово-инспирированные генетические алгоритмы (quantum-inspired genetic algorithms).** Показывают ускорение в 5–10 раз при поиске гиперпараметров в высокомерных пространствах признаков по сравнению с классическими методами [62, 63].

## 2 Анализ и реализация

Раздел посвящен последовательной реализации и эмпирическому обоснованию адаптивной торговой стратегии на базе моделей глубокого обучения для высоколиквидных активов российского фондового рынка. Структура раздела отражает необходимость учета специфических микро- и макроструктурных характеристик отечественного рынка, что определяет требования к этапам предобработки данных, параметризации моделей и оценке результатов. В самом начале проводится анализ и предобработка высокочастотных (5-минутных) данных. Исходя из динамических характеристик российского рынка, демонстрирующего эффекты кластеризации волатильности и высокую зашумленность внутридневных рядов, испытывается применение вейвлет-денойзинга. Метод позволяет отфильтровать стохастический шум, сохранив при этом предиктивные сигналы. Затем решается задача параметризации целевой переменной. В работе реализован принцип адаптивной разметки. Проанализирована зависимость оптимального параметра чувствительности (альфа) от профиля волатильности конкретного актива: показана целесообразность снижения данного параметра для высоковолатильных инструментов и его повышения для трендовых. Подход позволяет минимизировать влияние режимов с наибольшей волатильностью на качество обучения классификатора. В качестве последнего шага реализуется пространство признаков и проектируются архитектуры моделей. Для учета специфики российского рынка вектор признаков расширяется за счет интеграции макроэкономических индикаторов (ключевая ставка ЦБ РФ, инфляция, волатильность индекса МосБиржи).

**Технологический стек и вычислительные ресурсы.** Программная реализация всех этапов исследования выполнена на языке Python 3.11 с

использованием экосистемы библиотек для анализа данных, машинного обучения и интеграции с торговыми API.

### **Сбор и обработка данных.**

- T-Invest API (пакет tinkoff-investments 0.2.0-beta) – официальный SDK Т-Инвестиций для получения исторических 5-минутных котировок Московской биржи. В работе использована версия SDK с асинхронным клиентом AsyncClient. Для безопасного хранения токенов авторизации применялась библиотека python-dotenv 1.0.1, позволяющая изолировать учётные данные от основного кода.
- pandas 2.2.3 и numpy 1.26.4 – библиотеки для манипуляций с табличными данными и векторизованных вычислений.
- pyarrow 16.1.0 – работа с форматом Parquet, обеспечивающим эффективное сжатие и быстрое чтение/запись больших объёмов данных.
- scipy 1.14.1 – статистические функции. Расчёт минимально детектируемого эффекта, скользящих стандартных отклонений, тестов на значимость.

### **Машинное и глубокое обучение.**

- TensorFlow 2.17.0 и Keras 3.5.0 – основной фреймворк для реализации архитектур глубокого обучения (1D-CNN, BiLSTM с механизмом внимания, MLP). Для ускорения обучения на GPU применялась смешанная точность вычислений (mixed precision, политика mixed\_float16), что позволило сократить потребление видеопамяти и ускорить вычисления на тензорных ядрах NVIDIA T4 и V100 примерно в 1.5–2 раза без потери качества сходимости.
- scikit-learn 1.5.2 – базовые линейные модели (Ridge, Lasso), расчёт весов классов для работы с несбалансированной разметкой, а также метрики качества классификации.

- LightGBM 4.5.0 и CatBoost 1.2.7 – алгоритмы градиентного бустинга, использовавшиеся в качестве базовых моделей для сравнительного анализа.

- Optuna 3.6.1 – фреймворк для байесовской оптимизации гиперпараметров с поддержкой pruning (ранней остановки неперспективных испытаний).

### **Цифровая обработка сигналов.**

- PyWavelets 1.6.0 – библиотека для дискретного вейвлет-преобразования (DWT). Использован вейвлет семейства Symlet (sym4) с уровнем декомпозиции J=3.

### **Визуализация и сервисные библиотеки.**

- matplotlib 3.9.2 и seaborn 0.13.2 – построение графиков кривых капитала, распределений доходности, матриц ошибок и абляционных диаграмм.

- xlsxwriter 3.2.0 – экспорт сводных таблиц с результатами экспериментов в формат Excel для последующего анализа.

- tqdm 4.66.5 – отображение прогресса длительных вычислений (обучение моделей, walk-forward валидация).

### **Вычислительные ресурсы и распределение нагрузки.**

Эксперименты проводились на распределённой инфраструктуре. Google Colab Pro+ (GPU NVIDIA T4, 16 GB VRAM, расширенный объём RAM) – основная платформа для обучения моделей глубокого обучения. Здесь проведено 75% всех вычислений (примерно 300 часов GPU-времени), включая обучение 1D-CNN, BiLSTM с механизмом внимания и MLP на всех 16 активах в рамках схемы walk-forward validation. Использование смешанной точности (mixed\_float16) важно для T4, имеющей ограниченную видеопамять. Yandex DataSphere (GPU NVIDIA V100, 32 GB VRAM) использована для обучения на расширенном признаковом пространстве (OHLCV + технические индикаторы + макропризнаки) и подбора гиперпараметров. Selectel Cloud (GPU NVIDIA

V100) – эпизодическое использование для финальной верификации лучших моделей на тестовом периоде 2024–2025 гг. с инкрементальным дообучением. Локальная рабочая станция (Apple M4 Pro, 32 GB RAM) использована для предобработки данных (ETL-пайплайн), обучения базовых моделей машинного обучения и визуализации результатов.

**Общее время вычислений.** Полный цикл экспериментов (16 активов × 5 архитектур × walk-forward валидация с инкрементальным дообучением) составил около 400 часов GPU/CPU-времени.

**Воспроизводимость.** Полный код ETL-пайплайна, реализации адаптивной разметки, архитектур моделей и алгоритма бэкестинга доступен в публичном репозитории, ссылка на который находится в Приложение А. Файл requirements.txt содержит зафиксированные версии всех зависимостей, а скрипт автоматизирует запуск экспериментов с фиксированным random seed для обеспечения воспроизводимости результатов.

## 2.1 Сбор и подготовка данных

Процесс подготовки данных реализован в виде многоэтапного ETL-пайплайна, адаптированного под специфику API Т-Инвестиций и высокочастотных данных российского рынка.

**Извлечение данных.** Загрузка исторических котировок построена на базе API Тинькофф Инвестиций. Чтобы избежать ошибок маршрутизации, поиск инструмента по тикеру маппится на уникальный идентификатор FIGI. При этом применяется жесткая фильтрация: в выборку попадают только активы, торгующиеся в основных режимах Московской биржи (TQBR, TQCB, SPBFUT, CETS, TQTF), что исключает попадание в датасет внебиржевых инструментов и бумаг с альтернативных площадок. Для обхода лимитов API реализован механизм пакетного скачивания. Сам процесс сбора данных оптимизирован за счет инкрементального обновления локального кэша в формате Parquet: при повторном запуске пайплайн считывает последнюю

временную метку из кэша и дозагружает с сервера только недостающий кусок данных. На финальном шаге специфичный для API формат цен нормализуется в стандартные числовые типы для полей OHLCV.

**Преобразование и очистка.** Сырые рыночные данные содержат артефакты, требующие обязательной обработки перед подачей в модели. Нулевые значения в OHLC-полях (которые часто возникают при отсутствии сделок) приравниваются к пропускам (NA). Для их импутации используется метод прямого заполнения (forward fill), а для пропусков в самом начале истории — обратное (backward fill). Отсутствие объема (Volume) интерпретируется как нулевое значение. Для корректной работы моделей временных рядов формируется строгий временной индекс с заданной частотой, что устраняет разрывы, возникающие из-за задержек API или отсутствия торгов внутри сессии. Высоочастотные внутридневные данные агрегируются в дневные бары. Этот срез используется исключительно для расчета базовых метрик и бенчмарков.

**Загрузка.** Этот этап обеспечивает формирование выборок для обучения и тестирования моделей. Данные упорядочиваются по возрастанию времени. Подготовленные наборы данных сохраняются для последующего использования в обучении. Описанный подход к подготовке данных соответствует методологии работы [25] и обеспечивает согласованность, воспроизводимость и эффективность ETL-процесса.

## 2.2 Проектирование пространства признаков

Проектирование пространства признаков в работе выполнено как часть воспроизводимого плана подготовки данных для разных архитектур моделей. Основная задача данного этапа заключалась в том, чтобы преобразовать исходные 5-минутные свечи в тензоры фиксированной длины, пригодные для обучения нейронных сетей, при этом не допустить утечки информации из будущего и сохранить сопоставимость результатов между архитектурами. В

качестве базового набора признаков использовались стандартные OHLCV-поля: цена открытия, максимум, минимум, цена закрытия и объем торгов. Этот набор применялся во всех экспериментах как минимальная конфигурация признакового пространства. В программной реализации он задавался списком: *Open, High, Low, Close, Volume*

Такой выбор позволил проверить, способны ли модели глубокого обучения самостоятельно извлекать локальные паттерны из исходных рыночных данных без ручного добавления технических индикаторов.

**Архитектурно-зависимая подготовка входных данных.** Для разных типов моделей применялись разные способы представления входного ряда. Это связано с тем, что сверточные, полносвязные и рекуррентные архитектуры по-разному реагируют на масштаб цен, трендовость и нестационарность временных рядов. Для моделей 1D-CNN и MLP использовались исходные OHLCV-значения, преобразованные в скользящие окна длиной 24 наблюдения. При 5-минутной частоте данных такое окно соответствует двум часам торгов. После формирования тензоров нормализация выполнялась внутри каждой итерации скользящего тестирования: StandardScaler обучался только на обучающем фрагменте выборки, после чего применялся к validation- и test-частям того же окна. Это решение важно, так как исключает использование статистик тестового периода при масштабировании признаков.

В результате для CNN и MLP вход модели имел вид трехмерного тензора:

$$X \in R^{N \times 24 \times F},$$

где  $N$  — число обучающих примеров, 24 — длина исторического окна,  $F$  — количество признаков в выбранной конфигурации.

Для BiLSTM использовалась отдельная процедура приведения входов к стационарному виду. Абсолютные цены *Open*, *High* и *Low* нормировались относительно цены закрытия предыдущей свечи:

$$Open_t = Open_t / Close_{(t-1)} - 1.$$

$$High_t = High_t / Close_{(t-1)} - 1.$$

$$Low_t = Low_t / Close_{(t-1)} - 1.$$

Цена Close преобразовывалась в доходность текущей свечи, а объем торгов логарифмировался с помощью  $\log_{1p}(\text{Volume})$ .

**Формирование тензоров.** Для всех архитектур использовалась единая логика создания выборки. Данные предварительно сортировались по времени, после чего для каждого момента времени  $t$  формировалось историческое окно признаков:

$$X_t = [x_{t-24}, x_{t-23}, \dots, x_{t-1}].$$

Целевая метка рассчитана на основе будущей доходности за горизонт 24 свечи. При формировании тензоров выполнены проверки качества данных. С каждым запуском сохранялись дата и исходная цена закрытия, это позволило провести проверку на данных, на которых модель формировала вероятностные прогнозы.

**Технические индикаторы.** Для проверки гипотезы о полезности ручного конструирования признаков реализована функция добавления технических индикаторов. Она формировала расширенное признаковое пространство поверх базовых OHLCV-данных. Индикаторы сгруппированы по экономическому смыслу. К трендовым индикаторам относились простые скользящие средние SMA\_20, SMA\_50, SMA\_200, экспоненциальные средние EMA\_12, EMA\_26, а также индикатор MACD, его сигнальная линия и гистограмма. Эти признаки использовались для фиксации локального и среднесрочного направления движения цены. Первый блок описывает момент и волатильность: полосы Боллинджера, RSI (14), CCI (20), ADX (14) и ROC (12). Эти классические осцилляторы и трендовые фильтры дают модели понимание локального контекста: они помогают оценивать экстремумы (перекупленность/перепроданность), силу направленного движения и краткосрочный ценовой импульс. Следующий блок описывает объемные индикаторы (VWAP, OBV, ADL, CMF). При их интеграции в интрадей-модель мы столкнулись с методологической проблемой. Стандартные формулы On-



Balance Volume (OBV) и Accumulation/Distribution Line (ADL) предполагают бесконечное кумулятивное накопление. На внутридневных таймфреймах это приводит к тому, что абсолютные значения теряют смысл, а информация некорректно «перетекает» между сессиями: сети не нужен суммарный объем за три года, ей важен профиль ликвидности здесь и сейчас. Чтобы решить эту проблему, мы модифицировали расчет: для VWAP, OBV и ADL был применен механизм ежедневного сброса (daily reset). Признаки стали рассчитываться строго в границах одной торговой сессии. Это перевело их из разряда абсолютных метрик в относительные, сфокусировав внимание модели на реальном распределении капитала внутри текущего дня. При расчете ADL и CMF дополнительно обрабатывались случаи деления на ноль, возникающие при равенстве High и Low внутри свечи. Бесконечные значения заменялись нулями, чтобы не допустить попадания некорректных чисел в обучающие тензоры. После добавления технических индикаторов строки с пропущенными значениями удалялись. Такие пропуски неизбежно возникают в начале ряда из-за скользящих окон, например при расчете SMA\_200 или ADX\_14. Удаление выполнялось до формирования тензоров, чтобы в модель не попадали искусственно заполненные значения технических индикаторов.

**Макроэкономические признаки.** Отдельная ветка признакового пространства реализована для проверки влияния макроэкономического контекста на внутридневные модели. В нее включались признаки, отражающие состояние рынка и стоимость капитала:

1. Значение индекса Московской биржи.
2. 20-дневная волатильность индекса Московской биржи.
3. Относительная сила актива к индексу.
4. Ключевая ставка Банка России.
5. Годовая инфляция.

Для предотвращения утечки информации макроэкономические и рыночные признаки синхронизировались с 5-минутными наблюдениями с

учетом лага публикации. Значения индекса Московской биржи использовались со сдвигом на один торговый день: для торговли в день  $T$  модель получала информацию, доступную по итогам дня  $T-1$ . Ключевая ставка и инфляция объединялись с внутрисуточным рядом как низкочастотные признаки, действующие до следующего обновления значения. Макроэкономическая ветка признаков использовалась не во всех архитектурах, а как отдельный эксперимент для CDT 1D-CNN. Это сделано для чистоты абляционного анализа: модель тестировалась на базовых OHLCV-признаках и на OHLCV с добавлением макроэкономического контекста без одновременного добавления технических индикаторов. Такой дизайн позволил отдельно оценить, дает ли низкочастотная макроэкономическая информация самостоятельный вклад в высокочастотную торговую стратегию. В результате сформированы несколько экспериментальных конфигураций данных. Сводная информация по моделям представлена в Таблице 1. Для каждой архитектуры использована одинаковая базовая логика формирования скользящих окон и разметки. Это позволяет провести абляционный анализ: отдельно оценить вклад технических индикаторов, вейвлет-денойзинга и макроэкономических признаков в итоговые торговые результаты.

Таблица 1 – Матрица экспериментальных наборов признаков по моделям

| Модель | Базовые (OHLCV) | Технические индикаторы (ТИ) | Вейвлет-денойзинг | Макро-признаки | Цель эксперимента                                                 |
|--------|-----------------|-----------------------------|-------------------|----------------|-------------------------------------------------------------------|
| 1D-CNN | Да              | Да                          | Да                | Нет            | Оценка влияния фильтрации шума на извлечение локальных паттернов. |

|                      |    |     |     |     |                                                                                                 |
|----------------------|----|-----|-----|-----|-------------------------------------------------------------------------------------------------|
| BiLSTM,<br>Attention | Да | Да  | Нет | Нет | Проверка<br>необходимости<br>ручных ТИ для<br>моделирования<br>долгосрочных<br>зависимостей.    |
| MLP                  | Да | Да  | Нет | Нет | Оценка «нижней<br>границы» качества DL-<br>подходов.                                            |
| CDT 1-D<br>CNN       | Да | Нет | Нет | Да  | Проверка гипотезы о<br>самостоятельной<br>предсказательной силе<br>макроэкономического<br>фона. |

## 2.3 Методология адаптивной разметки целевой переменной

В работе реализована адаптивная волатильная разметка, при которой порог классификации динамически вычисляется на основе локального профиля волатильности актива. Структурная схема реализованной концепции представлена на рисунке 1. Подход близок к методу тройного барьера, однако вместо фиксации горизонтов Take-profit/Stop-loss в абсолютных величинах, использует волатильность как единицу измерения значимости движения.




Рисунок 1 – Структурная схема адаптивной разметки целевой переменной

### Математическая формулировка.

Пусть  $P_t$  – цена закрытия актива в момент времени  $t$ . Горизонт прогнозирования определяется размером окна  $W$  (в работе это 24 свечи, что соответствует 2 часам для 5-минутных данных). Доходность актива рассчитывается как:

$$R_{t,t+W} = \frac{P_{t+W} - P_t}{P_t}.$$

В качестве меры локальной волатильности  $\sigma_t$  используется скользящее среднеквадратическое отклонение исторических доходностей за N интервалов прогнозирования:

$$\sigma_t = STD(R_{t-N \cdot W}^{(W)}, \dots, R_{t-W}^{(W)}),$$

где  $R^{(W)}$  – доходность за интервал W, N – 10 (ширина окна оценки волатильности). N = 10 означает, что оценка волатильности базируется на поведении актива за последние 20 торговых часов, что позволяет адаптироваться к краткосрочным изменениям режимов без чрезмерного запаздывания.

Разметка классов (Labels: Up=1, Down=2, Flat=0) формируется по правилу:

$$L_t = \begin{cases} 1, R_{t,t+W} \geq \alpha \cdot \sigma_t, \\ 2, R_{t,t+W} \leq -\alpha \cdot \sigma_t, \\ 0, \text{ иначе,} \end{cases}$$

где  $\alpha$  – параметр чувствительности, определяющий, во сколько раз ожидаемая доходность должна превысить локальную волатильность для генерации торгового сигнала.

## **2.4 Эмпирическое обоснование подбора параметра чувствительности $\alpha$**

Процедура калибровки параметра  $\alpha$  реализована в виде итеративного алгоритма оптимизации, структурная схема которого представлена на рисунке 2. Методология включает последовательные этапы предобработки данных, поиска оптимального порога для каждого актива и кросс-секционного анализа распределения найденных значений.




Рисунок 2 – Структурная схема подбора параметра чувствительности  $\alpha$

На начальном этапе осуществляются временное выравнивание рядов и расчет базовых метрик. Для каждого инструмента из списка высоколиквидных активов выполняются:

1. Восстановление непрерывной временной сетки с дискретизацией 5 минут.
2. Замена нулевых ценовых значений пропущенными наблюдениями с последующей интерполяцией.
3. Расчет логарифмических доходностей за прогнозный горизонт  $W=24$  свечи (2 часа).

4. Оценка 5-минутной волатильности  $\sigma_t^{(5m)}$  как скользящего стандартного отклонения доходностей за окно длиной  $W$  наблюдений. Корректное приведение волатильности к целевому горизонту прогнозирования осуществляется по правилу квадратного корня времени:

$$\sigma_t^{(2h)} = \sigma_t^{(5m)} \cdot \sqrt{W}.$$

Для каждого тикера осуществляется перебор значений параметра  $\alpha$  в диапазоне  $\Delta\alpha=0.05$ . Классификация состояний рынка:

$$y_t = \begin{cases} +1, & r_{t,t+W} \geq +\alpha \cdot \sigma_t^{(2h)}, \\ -1, & r_{t,t+W} \leq -\alpha \cdot \sigma_t^{(2h)}, \\ 0, & \text{иначе.} \end{cases}$$

После классификации рассчитывается доля состояний Flat как отношение количества наблюдений с  $y_t = 0$  к общему числу наблюдений. Критерием оптимальности выступает минимизация абсолютного отклонения фактической доли Flat от целевого уровня  $\tau = 0.60$ :

$$\varepsilon(\alpha) = \left| \frac{1}{N} \sum_{i=1}^N \mathbb{I}(y_t^{(i)} = 0) - r \right| \rightarrow \min_{\alpha}.$$

Соотношение классов 60% Flat к 40% направленных движений (Up/Down) отражает структуру интрадей-рынка: большую часть времени активы находятся в боковике с низкой информационной активностью. Такой баланс не дает модели эффективно учиться на мажоритарном классе и заставляет фокусироваться на качестве предсказания именно в моменты разворотов и импульсов. Оптимизация гиперпараметра  $\alpha$  ведется методом полного перебора по заданной сетке. Для каждого тикера фиксируется значение  $\alpha^*$ , минимизирующее целевую функцию  $\varepsilon(\alpha)$ . После завершения оптимизации по всему датасету проводится статистический анализ распределения найденных оптимальных  $\alpha^*$  это позволяет оценить, насколько универсальным оказывается выбранное решение для разных активов. Результаты:

- Среднее  $\bar{\alpha} = 0.462$ .

- Медиана  $\tilde{\alpha} = 0.45$ .
- Мода  $\alpha_{mode} = 0.45$ .
- Стандартное отклонение  $\sigma_{\alpha} \approx 0.0289$ .

Порог  $\alpha_1 = 0.55$  задает консервативную стратегию. Это верхняя граница диапазона, где модель еще сохраняет стабильность. Такой фильтр отсеивает большинство ложных сигналов на шумных рынках и повышает итоговое соотношение сигнал/шум.

Порог  $\alpha_2 = 0.80$  решает обратную задачу. Он отбирает только самые уверенные предсказания модели. Классификатор, обученный на этой узкой выборке, фокусируется на максимальной точности, жертвуя количеством сделок ради их качества.

## 2.5 Обработка данных с помощью вейвлет-денойзинга

Применение вейвлет-денойзинга к 5-минутным данным продиктовано спецификой российского интрадея: рынок генерирует много микроструктурного шума, и классические сглаживающие фильтры просто размывают короткие ценовые импульсы, которые нужны для входа в позицию. Вейвлеты же подавляют шум селективно, поэтому в пилотных тестах мы сравнили несколько семейств. Daubechies низких порядков (db2, db3) оказались слишком агрессивными и срезали рабочие сигналы длиной в 2–4 бара, а Coiflet дали избыточную гладкость, стерев границы свечных паттернов. Оптимальным стал Symlet 4 (sym4) — его повышенная симметрия минимизирует фазовый сдвиг, что критически важно для точной временной локализации экстремумов и корректного определения момента пробоя уровней. С учетом того, что 5-минутный таймфрейм при длительности сессии 390 минут дает 78 баров в день.

Такой профиль декомпозиции точно отражает структуру внутрисдневной волатильности российского рынка, где микроструктурный шум оседает в d1, а значимые ценовые движения концентрируются в d2 и d3. Однако прямое



применение DWT ко всему историческому массиву нарушает принцип каузальности: из-за граничных эффектов преобразования коэффициент в момент  $t$  начинает зависеть от будущих значений ряда, создавая критическую утечку из будущего (look-ahead bias). Чтобы этого избежать, преобразование выполняется в скользящем окне длиной ровно в одну торговую сессию (78 баров) с использованием периодического расширения (`mode='periodization'`). Внутри каждого окна уровень шума оценивается через медиану абсолютных отклонений (MAD) детализирующих коэффициентов  $d1$  с поправочным делителем 0.6745 — эта метрика, в отличие от стандартного отклонения, устойчива к резким ценовым гэпам, после чего к  $d1$  применяется мягкая пороговая фильтрация для гладкого восстановления сигнала. Эмпирический подбор гиперпараметров подтвердил, что окно в 78 баров является строгим оптимумом: более короткие отрезки не дают достаточной статистики для оценки шума, а длинные захватывают данные предыдущего дня. Уровень декомпозиции  $J=3$  оказался золотой серединой между недоочисткой ( $J=2$ ) и избыточной фрагментацией сигнала ( $J=4, 5$ ), а независимая фильтрация каждого канала дала наилучший результат для 1D-CNN, позволив сверточным ядрам извлекать межканальные зависимости уже из очищенного тензора.

На активе YDEX применение вейвлет-денойзинга (`sym4`,  $J=3$ , окно 78 баров, мягкий порог) к OHLCV-данным перед подачей в 1D-CNN повысило доходность стратегии с 10.96% до 53.42% при сопоставимом уровне просадки. Это подтверждает зависимость свёрточных архитектур от качества входного сигнала. 1D-CNN не имеет встроенных механизмов фильтрации шума и передаёт его напрямую в последующие слои, где он накапливается и подавляет слабые предиктивные паттерны. Для рекуррентных архитектур (BiLSTM, GRU) преобразование не применялось. Причина методологическая: механизм скрытых состояний LSTM является фильтром с адаптивной памятью, и предварительное сглаживание ряда разрушает вариативность последовательности, на которой LSTM учится выделять значимые временные

зависимости. В экспериментах с BiLSTM применение вейвлет-денойзинга в проведенных экспериментах ухудшало метрики на 5–15%. Структурная схема реализованного подхода представлена на рисунке 3.



Рисунок 3 – Структурная схема реализации вейвлет-денойзинга

## 2.6 Базовые модели машинного обучения и эталонные инвестиционные модели

Для объективной оценки предсказательной способности разработанных архитектур глубокого обучения необходимо сравнение их результатов с базовыми моделями (baseline models) из области машинного обучения и классическими инвестиционными стратегиями (benchmarks).

**Классические модели машинного обучения.** В качестве базовых моделей использованы линейные регрессии с регуляризацией: Ridge (L2-штраф) и Lasso (L1-штраф). Ridge контролирует переобучение через штраф за квадратичную норму весов с параметром  $\alpha \in [0.001, 100]$ , тогда как Lasso дополнительно выполняет автоматический отбор признаков, обнуляя коэффициенты при неинформативных переменных. Обе модели требуют предварительной нормализации признаков (StandardScaler), поскольку регуляризация чувствительна к масштабу входных данных. Ансамблевые методы представлены градиентным бустингом в двух реализациях. LightGBM использует гистограммный алгоритм построения деревьев с параметрами:  $n\_estimators \in [100, 1000]$ ,  $learning\_rate \in [0.01, 0.3]$ ,  $max\_depth \in [3, 12]$ ,  $num\_leaves \in [31, 255]$ . CatBoost применяет упорядоченный бустинг (ordered boosting) для снижения целевой утечки и настраивается с  $iterations \in [100, 1000]$ ,  $learning\_rate \in [0.01, 0.3]$ ,  $depth \in [4, 10]$ . Обе модели способны улавливать нелинейные зависимости и взаимодействия признаков без явного указания, что делает их сильными базовыми линиями для сравнения с нейросетевыми архитектурами.

Все ML-модели обучаются на едином пространстве признаков: базовые OHLCV-данные + технические индикаторы (SMA, EMA, RSI, MACD, Bollinger Bands, ATR). Подбор гиперпараметров выполняется через Optuna с использованием метрики MAE для 50-200 итераций оптимизации. Валидация осуществляется через TimeSeriesSplit ( $n\_splits=5$ ) с сохранением временной

структуры данных. Ожидается ограниченная эффективность классических алгоритмов на высокочастотных 5-минутных данных из-за нестационарности временных рядов, наличия микроструктурного шума и нелинейных зависимостей, требующих предварительной обработки методами глубокого обучения. Структурная схема алгоритма представлена на рисунке 4.




Рисунок 4 – Структурная схема реализации классических моделей машинного обучения и подбора гиперпараметров

**Инвестиционные бенчмарки.** Оценка экономической эффективности стратегии проводится не только по метрикам (Sharpe, Profit Factor), но и в сравнении с пассивными стратегиями:

1. **Buy & Hold (Покупка и удержание).** Стратегия покупки актива в начале тестового периода и удержания до конца. Является главным

показателем доходности для оценки превышения доходности над рынком. Если стратегия не показывает доходность выше B&H с учетом комиссий, она не имеет практической ценности.

**2. DCA (Dollar Cost Averaging).** Усреднение стоимости покупки – регулярные покупки актива на фиксированную сумму, например, 10 и 25 числа каждого месяца. Стратегия позволяет оценить, может ли алгоритм превзойти доходность дисциплинированного инвестора, следующего стратегии эффективного рынка.

**3. Sell in May (Сезонная стратегия).** Классическая поговорка «Покупай в октябре, продавай в мае и уходи». Стратегия предполагает нахождение в рынке с ноября по апрель и активные продажи с мая по октябрь. Стратегия проверяет, способна ли нейросеть улавливать сезонность лучше, чем строго заданное эвристическое правило.

**4. Безрисковая ставка.** Доходность по банковским депозитам или ОФЗ. Используется в знаменателе коэффициента Шарпа для расчета премии за риск. В условиях высоких ставок ЦБ РФ (2024-2025 гг.) превышение доходности депозита является минимальным требованием к рискованной алгоритмической стратегии.

Интеграция инвестиционных стратегий в методологию исследования позволяет проверить, что прибыльность разработанной модели основана на извлечении предиктивного сигнала, а не на совпадении с глобальным рыночным трендом, который можно получить с помощью альтернативных способов размещения капитала.

## **2.7 Архитектуры моделей глубокого обучения**

Для проверки применимости методов глубокого обучения к задаче классификации рыночных состояний реализованы архитектуры: Cross-Data-Type 1D-CNN, классическая 1D-CNN, Bidirectional LSTM с механизмом временного внимания и глубокий многослойный перцептрон. Выбор

архитектур связан с способами обработки временных зависимостей. Сверточные сети извлекают локальные ценовые паттерны внутри короткого окна, рекуррентная сеть учитывает последовательность наблюдений, а полносвязная сеть служит нейросетевым базисом без явного механизма учета локальной структуры ряда. Все модели решают задачу многоклассовой классификации. На выходе формируется распределение вероятностей по трем классам: Flat, Buy и Sell. Последний слой каждой архитектуры содержит три нейрона с функцией активации softmax. В качестве функции потерь используется разреженная категориальная кросс-энтропия. Оптимизация параметров проводится алгоритмом Adam с шагом обучения  $10^{-3}$ . Обучение моделей организовано по единому плану. На каждом шаге формируются выборки: 100000 наблюдений для обучения, 2000 для валидации и 2000 для тестирования. После завершения итерации окно сдвигается на 2000 наблюдений. Масштабирование признаков выполнено отдельно внутри каждого окна. Дополнительно учитывается дисбаланс классов. Так как класс Flat встречается чаще классов Buy и Sell, при обучении рассчитываются веса классов методом взвешенного среднего. Для контроля переобучения применяется ранняя остановка по функции потерь на валидационной выборке и восстановлением лучших весов модели. В результате работы каждой модели сохраняются классы и вероятности классов Buy и Sell.

**Архитектура 1D-CNN с GlobalAveragePooling1D.** Традиционные CNN-архитектуры используют слой Flatten перед полносвязными слоями (Dense), что приводит к резкому росту числа параметров и высокому риску переобучения на зашумленных финансовых данных. Замена Flatten на GlobalAveragePooling1D вычисляет среднее значение по каждому feature map, превращая 3D-тензор в 1D-вектор. Таким образом каждый канал сверточного слоя становится детектором специфического паттерна для всего окна. Структурная схема архитектуры представлена на рисунке 5.




Рисунок 5 – Структурная схема архитектуры Cross-Data-Type 1D-CNN

**Классическая 1D-CNN.** Для классической 1D-CNN реализованы три варианта входных данных: OHLCV, OHLCV с техническими индикаторами, OHLCV после вейвлет-денойзинга. Последний вариант проверяет гипотезу о том, что предварительное подавление шума улучшает качество локальных сверточных фильтров. Структурная схема классической 1D-CNN представлена на рисунке 6.




Рисунок 6 – Структурная схема архитектуры 1D-CNN

**Bidirectional LSTM** с механизмом временного внимания применяется для проверки последовательных зависимостей внутри внутридневного окна. В отличие от сверточной сети, LSTM обрабатывает наблюдения как упорядоченную последовательность и учитывает зависимость текущего скрытого состояния от предыдущих элементов ряда. Структурная схема архитектуры BiLSTM+Attention представлена на рисунке 7. Перед подачей в LSTM входные признаки приводятся к более стационарному виду. Значения Open, High и Low нормируются относительно предыдущей цены Close, значение Close преобразуется в доходность текущей свечи, объем торгов логарифмируется функцией  $\log 1p$ .






Рисунок 7 – Структурная схема архитектуры BiLSTM+Attention

Использование Bidirectional LSTM позволяет учитывать как прямой, так и обратный порядок внутри исторического окна. Для данной архитектуры тестируются две конфигурации признаков: OHLCV без технических индикаторов и OHLCV с техническими индикаторами.

**Глубокий многослойный перцептрон.** Архитектура позволяет проверить, достаточно ли полносвязной сети для извлечения полезного сигнала из скользящего окна признаков. Структурная схема архитектуры Deep

MLP представлена на рисунке 8. MLP тестируется на OHLCV и на варианте с техническими индикаторами.




Рисунок 8 – Структурная схема архитектуры Deep MLP

Сравнение конфигураций необходимо для оценки того, помогает ли ручное расширение признакового пространства полносвязной сети или приводит к ухудшению обобщающей способности.

**Единая логика обучения и сохранения результатов.** На каждой итерации moving-window-пайплайна формируются обучающая, валидационная и тестовая части. После масштабирования признаков модель обучается на train-части, качество контролируется по validation-части, а вероятностные прогнозы сохраняются для test-части. После завершения итерации модель удаляется из памяти, сессия TensorFlow очищается, и окно сдвигается на следующий тестовый фрагмент. В качестве выходных данных сохраняются дата наблюдения, цена Close, фактическая метка класса, вероятность класса Buy и вероятность класса Sell. Такой формат отделяет этап прогнозирования от этапа торгового решения. Порог уверенности не фиксируется внутри модели, а подбирается позднее при бэктестинге. Это позволяет сравнивать разные значения порога на одних и тех же вероятностных прогнозах без повторного обучения моделей. Для продолжительных экспериментов реализован механизм промежуточного сохранения результатов. Для обеспечения отказоустойчивости при длительных облачных вычислениях пайплайн сохраняет промежуточные чекпоинты (прогнозные вероятности и фактические метки в Parquet) каждые 10 скользящих окон. По завершении полного бэктеста временные файлы очищаются, а результаты консервируются в едином датасете с привязкой к тикеру, архитектуре и параметру  $\alpha$ . Архитектурный стек намеренно сформирован из моделей с разными индуктивными смещениями (inductive biases), чтобы протестировать принципиально разные гипотезы. CNN ищет локальные микро-паттерны, BiLSTM с механизмом внимания анализирует глобальную последовательную структуру окна, классический MLP выступает бейзлайном для полносвязного преобразования признаков, а гибридный CDT 1D-CNN проверяет возможность скрещивания высокочастотного интрадея с

низкочастотным макро-контекстом. При этом финальная валидация намеренно выходит за рамки стандартных ML-метрик: в алгоритмическом трейдинге высокий F1-score сам по себе не гарантирует прибыли, поэтому решающим критерием отбора выступают риск-скорректированные показатели итоговой торговой стратегии.

## **2.8 Тестирование стратегии на исторических данных и риск-менеджмент**

Оценка экономической эффективности разработанных моделей невозможна без адекватного моделирования реальной торговли. В данном разделе описана схема тестирования, модель транзакционных издержек и алгоритм динамического риск-менеджмента (безубыток).

**Структурная схема скользящего окна (Walk-Forward Validation)** представлена на рисунке 9. Для предотвращения утечки данных из будущего и имитации реальной работы алгоритма в работе реализована схема скользящего окна – **Walk-Forward Validation**, имитирующая реальный процесс алгоритмической торговли. Особенностью реализованной схемы является использование **якорного (anchored) подхода с инкрементальным дообучением (fine-tuning)**. Параметры схемы валидации:

- Размер тренировочного окна – 48 месяцев.
- Размер тестового окна – 1 месяц.
- Шаг сдвига – 1 месяц.

Модель обучается на периоде  $[t_0, t_1]$ , тестируется на  $[t_1, t_2]$ , затем идет дообучение на новых данных за  $[t_1, t_2]$  и тест на  $[t_2, t_3]$ . Подробное описание этапов алгоритма:

**1. Инициализация и обучение.** На первых 48 месяцах данных (2020–2023 гг.) модель обучается с нуля (15–30 эпох). Формируются фильтры, способные распознавать свечные паттерны и структуру рынка.

**2. Прогнозирование.** Модель делает предсказания для каждого 5-минутного бара следующего месяца (тестового окна), не имея доступа к будущим ценам внутри этого месяца.

**3. Фильтрация сигналов.** Выход нейросети (вероятности классов) преобразуется в торговые сигналы с помощью порога уверенности (Confidence Threshold). Сигналы с низкой уверенностью (ниже 0.5) отбрасываются (присваивается класс Hold).

**4. Симуляция торговли.** На основе сгенерированных сигналов происходит векторизованное исполнение сделок с учетом транзакционных издержек и алгоритма безубытка.

**5. Инкрементальное дообучение.** После прохождения тестового месяца модель дообучается на новых, уже ставших историческими, данных всего за 1 эпоху. Это ключевой элемент: модель не переобучается с нуля, а корректирует веса для адаптации к возможному структурному сдвигу.

**6. Сдвиг окна.** Тестовый месяц присоединяется к обучающей выборке, и граница тестового окна сдвигается на 1 месяц вперед. Цикл повторяется до исчерпания исторических данных.




Рисунок 9 – Структурная схема алгоритма валидации со скользящим окном (Anchored Walk-Forward Validation with Fine-tuning)

**Модель расчета доходности с комиссиями.** Моделирование доходности стратегии учитывает не только ценовую динамику, но и транзакционные издержки, которые критичны для внутридневной торговли. Чистая доходность сделки ( $R_{net}$ ) рассчитывается по формуле:

$$R_{net} = \left( \frac{P_{exit}}{P_{entry}} - 1 \right) \cdot D - 2 \cdot C_{round} - S,$$

где:

- $P_{entry}, P_{exit}$  – цены входа и выхода соответственно.
- $D$  – направление сделки.
- $C_{round}$  – комиссия брокера и биржи (принята равной 0.03%).
- $S$  – проскальзывание, вызванное спредом спроса и предложения.

Для высоколиквидных бумаг принято равным 0.02%.

Учет проскальзывания и двойной комиссии (за вход и выход) делает результаты тестирования консервативными и приближенными к реальным условиям торговли.

Использование строгого стоп-лосса (Stop-Loss) на рынке РФ приводит к закрытию позиции из-за краткосрочного ценового выброса с последующим разворотом цены в предсказанном направлении. Для решения этой проблемы используется алгоритм динамического перевода позиции в безубыток. При достижении позицией заданного уровня прибыли, уровень стоп-лосса переносится в точку входа. Если цена разворачивается, позиция закрывается с нулевой прибылью. Алгоритм существенно повышает показатель Risk/Reward Ratio (RR).

### 3 Результаты и сравнительный анализ

В последней главе мы оцениваем работу алгоритмов и проверяем, приносят ли они реальную экономическую пользу. Структура главы построена как последовательная проверка гипотез: сначала мы смотрим, работает ли классическое машинное обучение, а затем сравниваем лучшие нейросети с традиционными инвестиционными стратегиями на российском рынке. Необходимо показать, что доходность моделей объясняется найденными закономерностями, а не переобучением, случайной удачей или скрытыми рисками. Для этого мы проводим тестирование в три этапа:

- **Оценка базовых моделей.** Проверка ограничений линейных моделей и градиентного бустинга демонстрировать статистически значимую прибыль на высокочастотных данных.
- **Сопоставление с макроэкономическими и рыночными бенчмарками.** Сравнение доходности алгоритмической стратегии с пассивными альтернативами размещения капитала, что позволяет обосновать практическую целесообразность использования активной торговли вместо пассивного инвестирования.
- **Сравнительный анализ архитектур глубокого обучения.** Оценка риск-скорректированной доходности (Sharpe Ratio, Profit Factor) и устойчивости (Max Drawdown) разработанных DL-моделей. Также тестирование значимости результатов с помощью расчета минимально детектируемого эффекта.

#### 3.1 Анализ эффективности классических моделей машинного обучения

В соответствии с методологией (п. 2.7), первым этапом проверки является оценка предсказательной способности классических алгоритмов машинного обучения. В таблице 2 представлены результаты базовых моделей



для четырех высоколиквидных активов, выступающих эмпирической базой исследования. На рисунке 10 визуализированы результаты в виде диаграмм. Для полноты анализа приводятся как классические метрики качества регрессии (MAE, RMSE), так и торговые метрики бэктеста.

Анализ представленных результатов выявляет следующие закономерности:

**1. Рассогласование ML-метрик и торговых результатов.**

Значения MAE и RMSE у линейных моделей и градиентного бустинга практически идентичны (например, на LKOH RMSE варьируется от 0.00459 до 0.00460). С точки зрения классического ML, CatBoost и Ridge решают задачу аппроксимации Z-score доходности с одинаковым качеством. Ridge показывает +4.60%, а CatBoost убыток -46.88%. Это указывает на то, что минимизация MSE в функции потерь не коррелирует с максимизацией торговой прибыли.

**2. Переобучение и overtrading.** На LKOH и Gold бустинг сгенерировал аномально высокое количество сделок (до 1136), что привело к падению Win Rate до 36-39% и существенно отрицательной доходности. Градиентный бустинг, обладая высокой емкостью модели, подстроился под случайные флуктуации обучающей выборки вместо выявления устойчивых паттернов. В условиях внутридневной торговли это проявляется как overtrading, то есть алгоритм торгует слишком часто.

**3. Провал ансамблирования.** Попытка усреднить Z-score прогнозов консервативной Ridge и агрессивной LightGBM не решила проблему, а усугубила её. Ансамбль унаследовал худшие свойства обеих моделей: на LKOH и GLDRUB он перенял высокую частоту торговли бустинга (425 и 1005 сделок), но сохранил низкий Win Rate (~39.5%). Единственный положительный кейс YDEX с доходностью +30.2% оказывается неубедительным после учета транзакционных издержек. Это показывает, что простое усреднение разнородных моделей без учета их торговых

характеристик не работает: ансамбль должен объединять модели с комплементарными сильными сторонами, а не модели с противоположными режимами торговли.

Таблица 2 – Результаты тестирования классических моделей машинного обучения на 5-минутных данных

| Тикер  | Модель   | MAE            | RMSE           | Сделки | WR, %       | Доход-<br>ть, % | PF          | Sharpe       | Стат.<br>знач. |
|--------|----------|----------------|----------------|--------|-------------|-----------------|-------------|--------------|----------------|
| SBER   | Ridge    | 0.00238        | 0.00421        | 111    | 55.9        | +7.18           | 1.29        | 3.38         | Нет            |
|        | Lasso    | 0.00237        | 0.00419        | 0      | -           | 0.00            | -           | -            | Нет            |
|        | LightGBM | 0.00237        | 0.00419        | 305    | 40.3        | -2.02           | 0.98        | -0.25        | Нет            |
|        | CatBoost | <b>0.00236</b> | <b>0.00418</b> | 295    | 51.9        | +14.45          | 1.23        | 2.31         | Нет            |
|        | Ensemble | -              | -              | 287    | 40.4        | +2.59           | 1.06        | 0.67         | Нет            |
| LKOH   | Ridge    | 0.00269        | 0.00460        | 23     | <b>69.6</b> | +4.60           | <b>2.70</b> | <b>13.42</b> | Нет            |
|        | Lasso    | 0.00268        | 0.00460        | 0      | -           | 0.00            | -           | -            | Нет            |
|        | LightGBM | 0.00269        | 0.00460        | 749    | 37.7        | -35.27          | 0.77        | -3.06        | Нет            |
|        | CatBoost | 0.00268        | 0.00459        | 803    | 36.7        | -46.88          | 0.70        | -3.87        | Нет            |
|        | Ensemble | -              | -              | 425    | 39.5        | -21.76          | 0.80        | -2.90        | Нет            |
| YDEX   | Ridge    | 0.00372        | 0.00610        | 91     | 60.4        | +42.21          | 2.10        | 10.72        | Нет            |
|        | Lasso    | 0.00372        | 0.00610        | 38     | 55.3        | +11.60          | 1.63        | 7.24         | Нет            |
|        | LightGBM | 0.00373        | 0.00611        | 650    | 44.3        | +13.80          | 1.08        | 0.98         | Нет            |
|        | CatBoost | 0.00371        | 0.00609        | 498    | 45.2        | <b>+42.64</b>   | 1.24        | 2.77         | Нет            |
|        | Ensemble | -              | -              | 502    | 47.0        | +30.21          | 1.17        | 2.09         | Нет            |
| GLDRUB | Ridge    | 0.00307        | 0.00478        | 985    | 43.6        | -54.74          | 0.70        | -4.75        | Да*            |

|  |          |         |         |      |      |        |      |        |     |
|--|----------|---------|---------|------|------|--------|------|--------|-----|
|  | Lasso    | 0.00299 | 0.00469 | 7    | 42.9 | +0.03  | 1.03 | 0.43   | Нет |
|  | LightGBM | 0.00317 | 0.00497 | 1136 | 39.7 | -72.49 | 0.58 | -7.11  | Да* |
|  | CatBoost | 0.00299 | 0.00470 | 26   | 26.9 | -3.36  | 0.20 | -17.94 | Нет |
|  | Ensemble | -       | -       | 1005 | 39.5 | -66.73 | 0.61 | -6.48  | Да* |

\* Примечание: статистическая значимость зафиксирована для убытка, то есть модель устойчиво приводит к отрицательному результату доходности, а не случайному шуму.

4. Ridge-регрессия демонстрирует крайне неустойчивые результаты: показывая слабую номинальную доходность на SBER и YDEX, она фиксирует статистически значимый убыток на GLDRUB. Такая сильная зависимость от конкретного тикера подтверждает неспособность линейных алгоритмов адаптироваться к смене рыночных режимов. Еще более показателен результат Lasso: на всех активах L1-регуляризация полностью обнуляет веса признаков. С точки зрения квантитативного анализа это жесткий индикатор того, что в сконструированном признаковом пространстве попросту отсутствует стабильный линейный альфа-сигнал. Финансовые зависимости в этих данных имеют выраженный нелинейный характер, поэтому использование линейных моделей в качестве самостоятельных торговых стратегий не имеет практического смысла.

#### Сравнение результатов базовых моделей




Рисунок 10 – Сравнение результатов базовых моделей по экономическим показателям

**Статистическая значимость** стратегий оценивалась через концепцию минимально детектируемого эффекта: сигнал признавался реальным, только если абсолютная средняя доходность на сделку превосходила этот порог. Показательным антикейсом стал тикер GLDRUB\_TOM, где Ridge, LightGBM и их ансамбль уверенно преодолели барьер MDE, но с отрицательным знаком. Это вскрывает классическую ловушку дата-майнинга: алгоритмы нашли не альфу, а устойчивый убыточный паттерн, и статистическая уверенность здесь означает лишь то, что модель стабильно теряет деньги. Обратная иллюзия возникает на LKOH и YDEX, где Ridge-регрессия выдала аномально высокие коэффициенты Шарпа (13.42 и 10.72). В реальности эти метрики экономически бессмысленны: за два года бэктеста модель совершила менее 100 сделок. На столь скудной выборке доверительные интервалы расширяются до неприемлемых значений, а запредельный Шарп оказывается

лишь артефактом малой выборки, не имеющим никакой прогностической силы на out-of-sample данных. Высокий Sharpe здесь – артефакт дисперсии единичных удачных входов. Ни один положительный результат базовых моделей не прошел проверку на статистическую значимость.

**Робастность и ограничения.** Необходимо явно выделить ограничения проведенного анализа базовых моделей:

- **Рыночный режим.** Тестирование проводилось на периоде 2024–2025 гг., характеризующемся высокой макроэкономической волатильностью. В условиях структурных сдвигов стационарные модели деградируют быстрее всего.
- **Учет издержек.** В бэктесте учтены транзакционные издержки (комиссия 0.03% + проскальзывание 0.02%). Именно они эродировать номинально положительные предсказания высокочастотных моделей.
- **Методология тестирования.** Использование TimeSeriesSplit защищает от проблемы заглядывания в будущее, но классический ML не обладает механизмами адаптации к концептуальному дрейфу в реальном времени.

Эмпирические данные показывают, что классические алгоритмы ML не способны извлечь воспроизводимый предиктивный сигнал из 5-минутных данных. Оптимизация по RMSE/DirAcc приводит к переобучению на шуме. Ансамблирование не фильтрует шум, а увеличивает оборот и комиссии. Этот вывод обосновывает переход к архитектурам глубокого обучения, способным извлекать инвариантные паттерны и использовать порог уверенности для фильтрации низкокачественных сигналов.

### 3.2 Сравнительный анализ архитектур глубокого обучения

Тестирование проводилось на данных за период 2024–2025 гг. Реализованы модели: Cross-Data-Type 1D-CNN (CDT-CNN), классическая 1D-CNN, Bidirectional LSTM с механизмом временного внимания и глубокий

многослойный перцептрон. Результаты сравнительного анализа представлены в таблице 3. Анализ таблицы показывает зависимость эффективности архитектуры от структуры актива. На GLDRUB MLP демонстрирует наибольшую доходность среди рассмотренных конфигураций. Архитектура CNN с вейвлет-преобразованием показывает минимальную просадку на золоте, подтверждая гипотезу о необходимости фильтрации шума. На активах с высокой долей поведенческой торговли доминирует рекуррентная архитектура BiLSTM+Attention, способная моделировать долгосрочные зависимости в сентимент-зависимых трендах. Применение вейвлет-денойзинга формирует наиболее плавную кривую капитала с минимальной волатильностью, тогда как MLP устойчиво приводит к более высокой совокупной доходности за счет принятия повышенного риска. На низколиквидных и зависимых от санкций активах все модели демонстрируют отрицательную доходность.

Таблица 3 – Сравнение риск-скорректированных метрик DL-архитектур по тикерам (период: 2024–2025 гг., комиссия 0.03%)

| Тикер  | Модель                     | Порог<br>(Threshold) | WFS           | Win<br>Rate, % | Profit<br>Factor | Return, %    | Max<br>DD, % | Sharpe      |
|--------|----------------------------|----------------------|---------------|----------------|------------------|--------------|--------------|-------------|
| GLDRUB | MLP<br>(wo TIs)            | 0.10                 | 0.8365        | 37.64          | 1.33             | <b>78.92</b> | -13.80       | <b>0.81</b> |
| GLDRUB | CNN (w<br>TIs)             | 0.35                 | 0.5375        | 42.92          | 1.29             | 28.16        | -9.32        | 0.51        |
| GLDRUB | CNN<br>(Wavelet<br>wo TIs) | 0.50                 | 0.8355        | 22.39          | 1.47             | 32.84        | -8.13        | 0.15        |
| GLDRUB | LSTM                       | 0.55                 | <b>0.9369</b> | 37.77          | 1.16             | 20.24        | -12.26       | -0.22       |

|      |                            |      |        |              |             |        |              |       |
|------|----------------------------|------|--------|--------------|-------------|--------|--------------|-------|
| SBER | LSTM                       | 0.65 | 0.8833 | 39.78        | <b>1.68</b> | 36.18  | <b>-4.08</b> | 0.37  |
| SBER | MLP<br>(wo TIs)            | 0.10 | 0.5836 | 44.17        | 1.14        | 28.85  | -24.08       | 0.08  |
| YDEX | LSTM                       | 0.15 | 0.6535 | <b>52.67</b> | 1.37        | 57.77  | -16.75       | 0.67  |
| YDEX | CNN<br>(Wavelet<br>wo TIs) | 0.20 | 0.5714 | 38.41        | 1.28        | 53.42  | -15.70       | 0.47  |
| LKOH | CNN<br>(wo TIs)            | 0.35 | 0.4977 | 13.03        | 1.35        | 20.49  | -10.40       | -0.24 |
| LKOH | MLP<br>(wo TIs)            | 0.10 | 0.5893 | 42.94        | 0.95        | -19.20 | -38.81       | -0.73 |

На рисунке 11 представлена динамика кривой капитала для тикера GLDRUB\_TOM, на котором стратегии демонстрируют устойчивый рост.




Рисунок 11 – Нормализованная кривая капитала (Equity Curve) для архитектур MLP и CNN (Wavelet) на активе GLDRUB\_TOM (2024–2025 гг.)

### 3.3 Анализ влияния пространства признаков

Для оценки вклада различных групп признаков проведен абляционный анализ. Результаты доходности моделей представлены в таблице 4.

Таблица 4 – Абляционный анализ влияния признакового пространства на доходность стратегий (Return, %)

| Тикер             | Модель | Base (OHLCV) | + TI         | + Wavelet    |
|-------------------|--------|--------------|--------------|--------------|
| <b>SBER</b>       | MLP    | 28.85        | -12.05       | –            |
| <b>SBER</b>       | LSTM   | 36.18        | -22.93       | –            |
| <b>SBER</b>       | CNN    | -1.93        | -12.05       | 3.95         |
| <b>GLDRUB_TOM</b> | MLP    | <b>78.92</b> | 23.60        | –            |
| <b>GLDRUB_TOM</b> | CNN    | 20.96        | 28.16        | 32.84        |
| <b>YDEX</b>       | LSTM   | 57.77        | 10.05        | –            |
| <b>YDEX</b>       | CNN    | 10.96        | <b>36.86</b> | <b>53.42</b> |

Основным наблюдением является ухудшение результата рекуррентных и полносвязных моделей при добавлении классических технических индикаторов (TI). Сверточные сети демонстрируют положительную реакцию на расширение признакового пространства за счет локальности сверточных фильтров. На рисунке 12 и в таблице 5 представлено влияние макро-факторов на базовую архитектуру CDT 1D-CNN.

Таблица 5 – Влияние макроэкономических признаков на метрики модели CDT 1D-CNN (SBER)

| Конфигурация                  | Размерность | WFS          | Return, %    | Sharpe Ratio | Profit Factor |
|-------------------------------|-------------|--------------|--------------|--------------|---------------|
| <b>Base (OHLCV)</b>           | 5           | 0.498        | <b>-23.3</b> | -7.17        | 0.80          |
| <b>+ MOEX Index</b>           | 8           | <b>0.508</b> | -40.3        | -6.12        | 0.84          |
| <b>+ Key Rate / Inflation</b> | 7           | <b>0.508</b> | -31.7        | <b>-4.76</b> | <b>0.88</b>   |
| <b>+ All Macro</b>            | 10          | 0.503        | -31.7        | <b>-4.76</b> | <b>0.88</b>   |



Добавление макроэкономических факторов приводит к снижению доходности с -23.3% до -40.3%. Результат является проблемой разности времени. В рамках окна макропеременные выступают как кусочно-постоянные функции, вызывая насыщение весов. Это указывает на ограниченную эффективность интеграции макроэкономических данных в интрадей-модели. Вейвлет-денойзинг показывает стабильное улучшение метрик. На тикере YDEX очистка OHLCV от шума повысила доходность CNN с 10.96% до 53.42%.




Рисунок 12 – Падение доходности и коэффициента Шарпа при добавлении низкочастотных макроэкономических данных в высокочастотную модель

### 3.4 Риск-менеджмент: динамический безубыток

Оптимизация профиля риска торговой системы осуществлялась посредством внедрения алгоритма динамического перевода позиции в безубыток. Математически это означает ограничивание левого хвоста распределения прибылей и убытков (P&L). При достижении нереализованной прибылью порогового значения +1% уровень Stop-Loss автоматически переносился в точку входа. Для предотвращения срабатывания безубытка на внутрисвечном шуме вводился фильтр минимального времени удержания позиции. В Таблице 6 представлено влияние алгоритма риск-менеджмента на метрики стратегии, демонстрирующей лучшую доходность (MLP на GLDRUB\_TOM).

Таблица 6 – Влияние алгоритма безубытка на метрики торговой стратегии (MLP, GLDRUB\_TOM)

| Метрика                                | Без безубытка | С безубытком<br>(+1%) | Абсолютное<br>изменение |
|----------------------------------------|---------------|-----------------------|-------------------------|
| <b>Взвешенный<br/>Risk/Reward (RR)</b> | 1.12          | 1.65                  | +0.53 (+47.3%)          |
| <b>Profit Factor</b>                   | 1.33          | 1.51                  | +0.18 (+13.5%)          |
| <b>Win Rate, %</b>                     | 37.64         | 52.10                 | +14.46 п.п.             |
| <b>Максимальная<br/>просадка, %</b>    | -13.80        | -9.20                 | +4.60 п.п.              |
| <b>Средний Holding<br/>Period</b>      | 2.5 часа      | 4.2 часа              | +1.7 часа               |

Применение механизма безубытка заметно изменяет распределение исходов сделки. Коэффициент Risk/Reward возрастает на 47.3%, что объясняется отсечением сделок, перешедших в положительную зону, но затем закрывшихся по Stop-Loss из-за возврата цены. Внедрение механизма динамического безубытка радикально меняет профиль стратегии. Win Rate вырастает с 37.64% до 52.10%, но не за счет увеличения прибыльных сделок, а за счет перевода части убыточных позиций в безубыточные. Алгоритм просто фиксирует позицию при первом же откате, отсекая потери на ранней стадии. Среднее время удержания увеличивается с 2.5 до 4.2 часов, модель перестает гоняться за каждым движением и начинает удерживать только те позиции, где тренд подтверждается. На высокочастотных данных российского рынка контроль левого хвоста распределения (минимизация крупных убытков) дает больший прирост риск-скорректированной доходности, чем попытка максимизации правого хвоста (поймка редких сверхприбыльных сделок).

Рынок слишком шумен, и дисциплинированный выход в безубыток сохраняет капитал для действительно сильных сигналов.

### 3.5 Минимально детектируемый эффект и статистическая значимость

В финансовой эконометрике MDE определяет минимальную величину выборочного среднего доходности, которая статистически значимо отличается от нуля. Формула MDE для уровня значимости 0.05 и мощности теста 0.80:

$$MDE = \frac{(Z_{1-\frac{\alpha}{2}} + Z_{1-\beta}) \cdot \sigma}{\sqrt{N}} \approx \frac{2.8 \cdot \sigma}{\sqrt{N}},$$

где  $\sigma$  – стандартное отклонение доходности сделок,  $N$  – количество сделок в выборке вне периода обучения. В таблице 7 представлен расчет MDE для моделей, показавших наилучшие результаты. Несмотря на подтверждение статистической значимости для части стратегий, экономическая интерпретация результатов требует сопоставления с альтернативными издержками капитала.

Таблица 7 – Расчет MDE и оценка статистической значимости стратегий (2024–2025 гг.)

| Тикер      | Модель       | Сделки | Ср. доходность сделки | Доход-ть | MDE    | Стат. Знач. | Sharpe |
|------------|--------------|--------|-----------------------|----------|--------|-------------|--------|
| GLDRUB_TOM | MLP (wo TIs) | 342    | 0.231%                | 0.84%    | 0.127% | Да          | 0.81   |
| GLDRUB_TOM | CNN (w TIs)  | 514    | 0.055%                | 0.92%    | 0.107% | Да          | 0.51   |
| SBER       | LSTM         | 218    | 0.166%                | 1.42%    | 0.270% | Да          | 0.37   |

|             |                 |     |        |              |        |     |       |
|-------------|-----------------|-----|--------|--------------|--------|-----|-------|
| <b>YDEX</b> | LSTM            | 295 | 0.196% | 1.15%        | 0.187% | Да  | 0.67  |
| <b>LKOH</b> | CNN (wo<br>TIs) | 410 | 0.050% | <b>1.88%</b> | 0.275% | Нет | -0.24 |

### Бенчмарки за тестируемый период:

- Ставка по депозитам: 16–21% годовых.
- Официальная инфляция: 9.5–11.9% годовых.
- Индекс МосБиржи: 18% годовых.

Анализ показывает, что доходность лучшей безрисковой альтернативы (21% по депозитам) существенно превосходит риск-скорректированную доходность большинства DL-стратегий на активах SBER и GLDRUB\_TOM. Модель LSTM на YDEX показывает доходность 57.77%, однако с учетом просадки в -16.75% и транзакционных издержек, коэффициент Шарпа (0.67) указывает на неудовлетворительное соотношение риск/прибыль по сравнению с пассивным размещением капитала под проценты. В результате, даже в случаях формального отвержения нулевой гипотезы (по критерию MDE), разработанные стратегии не демонстрируют превосходства над пассивным инвестированием в условиях строгой монетарной политики ЦБ РФ. Данный эмпирический результат указывает на пользу гипотезы эффективного рынка (ЕМН): на высокочастотном горизонте российского рынка алгоритмическая торговля на базе DL позволяет минимизировать просадки и фильтровать шум, но не продемонстрировала устойчивую арбитражную доходность, превосходящую безрисковую ставку. Это обосновывает целесообразность применения DL-моделей в первую очередь как инструментов риск-менеджмента и анализа режимов рынка, а не как автономных генераторов альфы.

## ЗАКЛЮЧЕНИЕ

В работе спроектирована и протестирована внутридневная нейросетевая стратегия для российского фондового рынка. Фокус исследования сделан на оценке алгоритма в реальных условиях: с учетом комиссий, проскальзывания и смены рыночных режимов.

Внедрена адаптивная волатильная разметка. Пороги классов подстраиваются под локальную волатильность и текущий режим рынка, а не задаются жестко. Добавление классических техиндикаторов чаще выступало шумом и снижало доходность. Вейвлет-деноизинг дает прирост только для сверточных архитектур, а низкочастотные макро-данные оказались бесполезны для внутридневной торговли из-за рассогласования частот.

Классические модели машинного обучения не смог показать стабильную доходность. Итоговый алгоритм мы построили на вероятностных прогнозах DL-моделей, добавив механизм динамического безубытка. Это существенно улучшило профиль риска: снизилась максимальная просадка и выросла доля неубыточных сделок.

Расчет минимально детектируемого эффекта подтвердил наличие статистически значимого сигнала на ряде активов. Однако статистика уперлась в экономику: в условиях высокой ключевой ставки безрисковая доходность задает крайне жесткий бенчмарк. С поправкой на риск и транзакционные издержки большинство протестированных стратегий не смогли его превзойти.

Модели глубокого обучения отлично справляются с определением рыночных режимов, фильтрацией сигналов и контролем просадок, но использовать их как автономный источник доходности преждевременно. Их практическая ценность в роли интеллектуального модуля риск-менеджмента.

Дальнейшее развитие стратегии мы видим в следующих направлениях:

- Переход к мультимодальным архитектурам.

- Интеграция данных стакана заявок с учетом рыночного воздействия.
- Применение архитектур, работающих с разными частотами, и методов непрерывного обучения для адаптации к структурным сдвигам рынка.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Fama E. F. Efficient capital markets: A review of theory and empirical work // The Journal of Finance. – 1970. – Vol. 25, № 2. – P. 383–417.
2. Samuelson P. A. Proof that properly anticipated prices fluctuate randomly // Industrial Management Review. – 1965. – Vol. 6, № 2. – P. 41–49.
3. Lo A. W. The adaptive markets hypothesis // The Journal of Portfolio Management. – 2004. – Vol. 30, № 5. – P. 15–29.
4. Dimson E., Marsh P. Murphy's law and market anomalies // The Journal of Portfolio Management. – 1999. – Vol. 25, № 2. – P. 53–69.
5. Lo A. W., MacKinlay A. C. Stock market prices do not follow random walks: Evidence from a simple specification test // The Review of Financial Studies. – 1988. – Vol. 1, № 1. – P. 41–66.
6. Achelis S. B. Technical Analysis from A to Z. – New York : McGraw Hill, 2001. – 380 p.
7. Brock W., Lakonishok J., LeBaron B. Simple technical trading rules and the stochastic properties of stock returns // The Journal of Finance. – 1992. – Vol. 47, № 5. – P. 1731–1764.
8. Lo A. W., Mamaysky H., Wang J. Foundations of technical analysis: Computational algorithms, statistical inference, and empirical implementation // The Journal of Finance. – 2000. – Vol. 55, № 4. – P. 1705–1765.
9. Dixon M., Klabjan D., Bang J. H. Classification-based financial markets prediction using deep neural networks // Algorithmic Finance. – 2017. – Vol. 6, № 3-4. – P. 67–77.
10. Kim K. J. Financial time series forecasting using support vector machines // Neurocomputing. – 2003. – Vol. 55, № 1-2. – P. 307–319.
11. Hochreiter S., Schmidhuber J. Long short-term memory // Neural Computation. – 1997. – Vol. 9, № 8. – P. 1735–1780.
12. Ding X., Zhang Y., Liu T. [et al.] Deep learning for event-driven stock prediction // Proceedings of the Twenty-Fourth International Joint Conference on Artificial Intelligence (IJCAI). – Buenos Aires, 2015. – P. 2327–2333.
13. Aiolfi M., Favero C. A. Model uncertainty, thick modelling and the predictability of stock returns // Journal of Forecasting. – 2005. – Vol. 24, № 4. – P. 233–254.

14. Kingma D. P., Ba J. Adam: A method for stochastic optimization [Электронный ресурс] // arXiv:1412.6980. – 2014. – URL: <https://arxiv.org/abs/1412.6980> (дата обращения: 05.03.2026).
15. Zhang L., Aggarwal C., Qi G. J. Stock price prediction via discovering multi-frequency trading patterns // Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. – Halifax, 2017. – P. 2141–2149.
16. Krizhevsky A., Sutskever I., Hinton G. E. ImageNet classification with deep convolutional neural networks // Advances in Neural Information Processing Systems 25 (NeurIPS 2012). – 2012. – P. 1097–1105.
17. Zeiler M. D., Fergus R. Visualizing and understanding convolutional networks // European Conference on Computer Vision (ECCV 2014). – Cham : Springer, 2014. – P. 818–833.
18. Sun T., Wang J., Zhang P. [et al.] Predicting stock price returns using microblog sentiment for Chinese Stock Market // Proceedings of the 3rd International Conference on Big Data Computing and Communications (BIGCOM). – Chengdu, 2017. – P. 87–96.
19. Московская Биржа. Отчёт о развитии рынка акций и облигаций в 2023 году [Электронный ресурс]. – М., 2024. – URL: <https://www.moex.com/a2565> (дата обращения: 05.03.2026).
20. Центральный банк Российской Федерации. Доклад о денежно-кредитной политике [Электронный ресурс]. – М., 2025. – URL: <https://www.cbr.ru/dkrp/> (дата обращения: 05.03.2026).
21. Федеральная служба государственной статистики. Индексы потребительских цен [Электронный ресурс]. – М., 2026. – URL: <https://rosstat.gov.ru/folder/10705> (дата обращения: 05.03.2026).
22. Glorot X., Bengio Y. Understanding the difficulty of training deep feedforward neural networks // Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics (AISTATS). – 2010. – P. 249–256.
23. Glorot X., Bordes A., Bengio Y. Deep sparse rectifier neural networks // Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics (AISTATS). – 2011. – P. 315–323.
24. Rechenthin M. D. Machine-learning classification techniques for the analysis and prediction of high-frequency stock direction : PhD thesis. – Iowa City : University of Iowa, 2014. – 187 p.



25. Lopez de Prado M. *Advances in Financial Machine Learning*. – Hoboken : Wiley, 2018. – 400 p.
26. Sullivan R., Timmermann A., White H. Data-snooping, technical trading rule performance, and the bootstrap // *The Journal of Finance*. – 1999. – Vol. 54, № 5. – P. 1647–1691.
27. Росстат. Методология расчёта индекса потребительских цен [Электронный ресурс]. – М., 2025. – URL: [https://rosstat.gov.ru/storage/mediabank/metodologia\\_ipc.pdf](https://rosstat.gov.ru/storage/mediabank/metodologia_ipc.pdf) (дата обращения: 05.03.2026).
28. Центральный банк РФ. Статистические бюллетени Банка России [Электронный ресурс]. – М., 2026. – URL: <https://www.cbr.ru/statistics/bs/> (дата обращения: 05.03.2026).
29. Goodfellow I., Bengio Y., Courville A. *Deep Learning*. – Cambridge : MIT Press, 2016. – 775 p.
30. Ozbayoglu M. A., Gudelek M. U., Sezer O. B. Deep learning for financial applications: A survey // *Applied Soft Computing*. – 2020. – Vol. 93. – Art. 106384.
31. Zhang C., Sjarif N. N. A., Ibrahim R. Deep learning models for price forecasting of financial time series [Электронный ресурс] // arXiv:2305.04811. – 2023. – URL: <https://arxiv.org/pdf/2305.04811.pdf> (дата обращения: 05.03.2026).
32. Wang J., Zhang Y., Liu X. Cross-data-type feature extraction for financial time series prediction using convolutional neural networks // *Expert Systems with Applications*. – 2023. – Vol. 215. – Art. 119345. – DOI: 10.1016/j.eswa.2022.119345.
33. Wang J. [et al.] Financial Markets Prediction with Deep Learning [Электронный ресурс] // arXiv:2104.05413. – 2021. – URL: <https://arxiv.org/abs/2104.05413> (дата обращения: 05.03.2026).
34. Sulimov I., Lyell J. Using Sentiment Analysis of News for Predicting Russian Stock Market Prices // *Analysis of Images, Social Networks and Texts (AIST 2022)*. – Cham : Springer, 2022. – P. 108–119. – DOI: 10.1007/978-3-031-23171-2\_9.
35. Хазиев Г. А., Соколова Т. В. Прогнозирование доходности российских акций на основе анализа настроений инвесторов в социальных сетях // *Экономика и математические методы*. – 2025. – Т. 61, № 1. – С. 95–108. – DOI: 10.31857/S0424738825010095.
36. Teplova T., Fayzulin M., Kurkin A. Early warning system for Russian stock market crises: TCN-LSTM-Attention model using imbalanced data and attention mechanism //

Socio-Economic Planning Sciences. – 2025. – Vol. 101. – Art. 102292. – DOI: 10.1016/j.seps.2025.102292.

37. Chatzis S. P., Siakoulis V., Petropoulos A. [et al.] Forecasting stock market crisis events using deep and statistical machine learning techniques // Expert Systems with Applications. – 2018. – Vol. 112. – P. 353–371. – DOI: 10.1016/j.eswa.2018.06.050.

38. Bekaert G., Hodrick R. J. International Financial Management. – 3rd ed. – Cambridge : Cambridge University Press, 2023. – 684 p.

39. OECD. Business Insights on Emerging Markets 2024 [Электронный ресурс]. – 2024. – URL: [https://www.oecd.org/en/publications/business-insights-on-emerging-markets-2024\\_7d6b7375-en.html](https://www.oecd.org/en/publications/business-insights-on-emerging-markets-2024_7d6b7375-en.html) (дата обращения: 05.03.2026).

40. Faizulin M. S. Behavioural Deviations and Fractal Patterns in the Russian Stock Market [Электронный ресурс] // Journal of Applied Economic Research. – 2025. – URL: <https://ideas.repec.org/a/aiy/jnjaer/v24y2025i3p1023-1064.html> (дата обращения: 05.03.2026).

41. Кох И. А. Применение мультипликаторов на базе выручки в оценке стоимости нефтегазовых корпораций // Корпоративные финансы. – 2013. – Т. 7, № 1 (25). – С. 103–113.

42. Geopolitical risks: implications for asset prices and financial stability [Электронный ресурс] // IMF Global Financial Stability Report. – 2025. – URL: <https://www.imf.org/-/media/files/publications/gfsr/2025/april/english/ch2.pdf> (дата обращения: 05.03.2026).

43. Асайын Е. Ж., Барлыбаев А., Шарипбай А. Методы глубокого обучения в прогнозировании фондового рынка: обзор и будущие направления [Электронный ресурс] // Вестник науки. – 2024. – Т. 4, № 11 (80). – С. 112–125. – URL: <https://cyberleninka.ru/article/n/metody-glubokogo-obucheniya-v-prognozirovanii-fondovogo-rynka-obzor-i-buduschie-napravleniya> (дата обращения: 05.03.2026).

44. Dierckx T., Davis J., Schoutens W. Using Machine Learning and Alternative Data to Predict Movements in Market Risk [Электронный ресурс] // arXiv:2009.07947. – 2020. – URL: <https://arxiv.org/abs/2009.07947> (дата обращения: 05.03.2026).

45. Tatarinov N. [et al.] Language Modeling for the Future of Finance: A Quantitative Survey into Metrics, Tasks, and Data Opportunities [Электронный ресурс] // arXiv:2504.07274. – 2025. – URL: <https://arxiv.org/abs/2504.07274> (дата обращения: 05.03.2026).

46. Taylor K., Ng J. Natural Language Processing and Multimodal Stock Price Prediction [Электронный ресурс] // arXiv:2401.01487. – 2024. – URL: <https://arxiv.org/abs/2401.01487> (дата обращения: 05.03.2026).
47. Thorp E. O. The Kelly Criterion in Blackjack, Sports Betting, and the Stock Market // Handbook of Asset and Liability Management. – Vol. 1. – Amsterdam : North-Holland, 2006. – P. 385–428. – DOI: 10.1016/B978-044453248-0.50015-0.
48. Kelly J. L. Jr. A New Interpretation of Information Rate // Bell System Technical Journal. – 1956. – Vol. 35, № 4. – P. 917–926. – DOI: 10.1002/j.1538-7305.1956.tb03809.x.
49. Cover T. M., Thomas J. A. Elements of Information Theory. – 2nd ed. – Hoboken : John Wiley & Sons, 2006. – 748 p.
50. Haghani V., Dewey R. Rational Decision-Making Under Uncertainty: Observed Betting Patterns on a Biased Coin // The Journal of Portfolio Management. – 2016. – Vol. 42, № 5. – P. 12–25. – DOI: 10.3905/jpm.2016.42.5.012.
51. MacLean L. C., Thorp E. O., Ziemba W. T. Long-Term Capital Growth: The Good and Bad Properties of the Kelly and Fractional Kelly Capital Growth Criteria // Quantitative Finance. – 2010. – Vol. 10, № 7. – P. 681–687. – DOI: 10.1080/14697688.2010.500628.
52. Sun E. W., Meinel T. A new wavelet-based denoising algorithm for high-frequency financial data mining // European Journal of Operational Research. – 2012. – Vol. 217, № 2. – P. 446–456. – DOI: 10.1016/j.ejor.2011.09.035.
53. Ranta M. Wavelet multiresolution analysis of financial time series : PhD thesis. – Vaasa : University of Vaasa, 2010. – 223 p.
54. Donoho D. L., Johnstone I. M. Ideal spatial adaptation by wavelet shrinkage // Biometrika. – 1994. – Vol. 81, № 3. – P. 425–455. – DOI: 10.1093/biomet/81.3.425.
55. Zhang Y. [et al.] Prediction of financial time series using LSTM and data denoising based on wavelet transform [Электронный ресурс] // arXiv:2103.03505. – 2021. – URL: <https://arxiv.org/abs/2103.03505> (дата обращения: 05.03.2026).
56. Hoque M. R. [et al.] Reinforcement Learning in Financial Decision Making: A Systematic Review of Performance, Challenges, and Implementation Strategies [Электронный ресурс] // arXiv:2512.10913. – 2025. – URL: <https://arxiv.org/abs/2512.10913> (дата обращения: 05.03.2026).
57. Ferrell B., Thomson McInnes B. A Comprehensive Survey on the Integration of Reinforcement Learning and NLP for Stock Market Trading [Электронный ресурс] // SSRN Electronic Journal. – 2025. – DOI: 10.2139/ssrn.5135573.

58. Hambly B., Xu R., Yang H. Recent advances in reinforcement learning in finance // *Mathematical Finance*. – 2023. – Vol. 33, № 3. – P. 437–503. – DOI: 10.1111/mafi.12394.
59. Théate T., Ernst D. An Application of Deep Reinforcement Learning to Algorithmic Trading // *Expert Systems with Applications*. – 2021. – Vol. 173. – Art. 114632. – DOI: 10.1016/j.eswa.2021.114632.
60. Пономарев Е. С., Оселедец И. В., Чихоцкий А. С. Применение обучения с подкреплением в задаче алгоритмической торговли // *Искусственный интеллект и принятие решений*. – 2019. – № 2. – С. 32–45.
61. Felizardo L. K. [et al.] Reinforcement Learning Applied to Trading Systems: A Survey [Электронный ресурс] // arXiv:2212.06064. – 2022. – URL: <https://arxiv.org/abs/2212.06064> (дата обращения: 05.03.2026).
62. Bhuiyan M. S. M. [et al.] Deep Learning for Algorithmic Trading: A Systematic Review // *Array*. – 2025. – Vol. 25. – Art. 100421. – DOI: 10.1016/j.array.2024.100421.
63. Yasin A. S., Gill P. S. RL Framework for Quantitative Trading: Multi-Agent Approaches under Partial Observability [Электронный ресурс] // arXiv:2411.07585. – 2024. – URL: <https://arxiv.org/abs/2411.07585> (дата обращения: 05.03.2026).

## ПРИЛОЖЕНИЕ А

Ссылка на репозиторий программной реализации:  
[https://github.com/JayRox73/fqw\\_master\\_degree](https://github.com/JayRox73/fqw_master_degree)